

T.C.
SAKARYA ÜNİVERSİTESİ
MÜHENDİSLİK FAKÜLTESİ

ENDÜSTRİ MÜHENDİSLİĞİ BÖLÜMÜ

BİTİRME ÇALIŞMASI

Brent Petrol Fiyatlarının Jeopolitik Risk ve Volatilité Endeksi Kullanılarak Hibrit
Makine Öğrenmesi Modelleri ile Tahmini

HAZIRLAYAN

Mustafa Enes Yeşilyurt

DANIŞMAN

Dr. Öğr. Üyesi Abdullah Hulusi Kökçam

Haziran 2026

İÇİNDEKİLER

TEŞEKKÜR	i
TABLolar LİSTESİ	ii
ŞEKİLLER LİSTESİ	iii

ÖZET	6
BÖLÜM 1. GİRİŞ	8
BÖLÜM 2. PROBLEMİN TANIMI	16
BÖLÜM 3. PROBLEMİN ÇÖZÜMÜ TAKİP EDİLECEK AŞAMALAR	17
BÖLÜM 4. UYGULAMA	19
BÖLÜM 5. İSTATİSTİKSEL ANALİZ	44
BÖLÜM 6. GERÇEKÇİ KISITLAR VE KOŞULLAR ALTINDA DEĞERLENDİRME	50
BÖLÜM 7. SONUÇ	51
KAYNAKLAR	54

TEŞEKKÜR

Bu çalışmanın hazırlanması sürecinde bilgi ve deneyimleriyle bana rehberlik eden, değerli görüş ve önerileriyle çalışmanın her aşamasında destek sağlayan danışman hocam Abdullah Hulusi Kökçam'a içten teşekkürlerimi sunarım.

Lisans eğitimim boyunca bilgi ve tecrübeleriyle akademik gelişimime katkı sağlayan tüm öğretim üyelerine teşekkür ederim.

Çalışmanın gerçekleştirilmesi sürecinde desteklerini esirgemeyen, veri toplama ve analiz aşamalarında yardımcı olan arkadaşlarıma teşekkür ederim.

Ayrıca eğitim hayatım boyunca maddi ve manevi desteklerini her zaman yanımda hissettiğim, bana güvenen ve her koşulda destek olan aileme sonsuz teşekkürlerimi sunarım.

TABLÖLAR LİSTESİ

Tablo 1: Sistem Bileşenleri	17
Tablo 2: Çözüm Aşamaları	18
Tablo 3: Veri Seti İlk 5 Satır	20
Tablo 4: Tanımlayıcı İstatistikler	21
Tablo 5: Dalgacık Dönüşümü Sonrası Karşılaştırma	24
Tablo 6: Özellik Mühendisliğinde Oluşturulan Özellikler	28
Tablo 7: ADF Test Sonuçları	30
Tablo 8: XGBoost Hiperparametre Havuzu	32
Tablo 9: Optimize Edilmiş XGBoost Sonuçları	32
Tablo 10: LSTM Modeli	35
Tablo 11: LSTM Hiperparametre Havuzu	37
Tablo 12: LSTM Sonuçları	38
Tablo 13: Hibrit Model Sonuçları	40
Tablo 14: Hibrit Model Hiperparametre Sonuçları	40
Tablo 15: Optimize Edilmiş Hibrit Model Sonuçları	41
Tablo 16: Modellerin Performans Metriklerinin Karşılaştırılması	42
Tablo 17: Diebold-Mariano Test Sonuçları	45
Tablo 18: Model Sonuçları	53

ŞEKİLLER LİSTESİ

Şekil 1. Brent Petrol, OVX ve GPR Değişkenlerinin Zaman Serisi Grafiği	22
Şekil 2. GPRD İçin Dalgacık Dönüşümü Gösterimi	23
Şekil 3. Logaritmik Dönüşüm Grafiği	25
Şekil 4. Brent Petrol Fiyatının Otokorelasyon Grafiği	29
Şekil 5. XGBoost Gerçek vs. Tahmin Grafiği	33
Şekil 6. LSTM Loss Grafiği	36
Şekil 7. LSTM Gerçek vs. Tahmin Grafiği	38
Şekil 8. Hibrit Model Gerçek vs. Tahmin Grafiği	42
Şekil 9. SHAP Özet Grafiği	47
Şekil 10. SHAP Katkı Oranları Grafiği	49

ÖZET

Küresel enerji piyasalarının en stratejik bileşenlerinden biri olan ham petrol fiyatları; arz-talep dengesinin yanı sıra finansal oynaklıklar ve jeopolitik belirsizliklerden doğrudan etkilenen doğrusal olmayan bir yapı sergilemektedir. Özellikle son yıllarda yaşanan küresel krizler, savaşlar ve piyasa şokları, petrol fiyat tahminlemede veri odaklı ve ileri düzey modelleme yaklaşımlarının önemini artırmıştır. Bu çalışmada, Brent ham petrol fiyatlarının tahmin edilmesinde Petrol Volatilite Endeksi (OVX) ile Jeopolitik Risk Endeksi (GPR) değişkenlerinin etkileri makine öğrenmesi algoritmaları aracılığıyla analiz edilmiştir.

Çalışmanın metodolojik çerçevesi; 2014–2024 yıllarını kapsayan veri setinin entegrasyonu, veri ön işleme süreçleri, sinyal işleme teknikleri ve hibrit makine öğrenmesi modellerinden oluşmaktadır. Veri setindeki finansal gürültülerin azaltılması amacıyla Dalgacık Dönüşümü yöntemi uygulanmış, ayrıca logaritmik dönüşüm, winsorizasyon ve Min-Maks ölçeklendirme yöntemlerinden yararlanılmıştır. Model performansını artırmak amacıyla gecikmeli değişkenler ve üstel hareketli ortalama (EMA) tabanlı özellik mühendisliği çalışmaları gerçekleştirilmiştir.

Çalışmada XGBoost, LSTM ve hibrit modelleri geliştirilmiş; modeller RMSE, MAE, MAPE ve R^2 performans metrikleri üzerinden değerlendirilmiştir. Elde edilen sonuçlar, hibrit model yaklaşımının özellikle yüksek volatilité dönemlerinde daha güçlü performans gösterdiğini ortaya koymuştur. 2014–2024 test sonuçlarında hibrit model yaklaşık %83 açıklayıcılık düzeyine ulaşırken, düşük hata oranları ile başarılı tahmin sonuçları üretmiştir. 2024-2026 arası test verilerinde ise %93 açıklayıcılık düzeyine ulaşmıştır. Bunun sebebi olarak ise 2024-2026 yılları arasındaki volatilité hareketlerinin eğitim veri setinin yapısına daha çok uyduğu gözükmektedir. Ayrıca gerçekleştirilen volatilité rejim analizi, hareketli tahmin hatası analizi ve ortalama yönsel doğruluk sonuçları; OVX endeksinin petrol fiyat tahmin performansı üzerinde önemli etkiler oluşturduğunu göstermektedir.

Genel olarak çalışma, hibrit makine öğrenmesi modellerinin Brent petrol fiyat tahmininde güçlü sonuçlar üretebildiğini ve finansal zaman serilerinde veri odaklı tahminleme yaklaşımlarının etkinliğini ortaya koymaktadır.

Anahtar kelimeler: Brent Petrol, Jeopolitik Risk Endeksi (Geopolitical Risk Index), Ham Petrol Volatilite Endeksi (Oil Volatility Index), Zaman Serisi Tahmini (Time Series Forecasting), Dalgacık Dönüşümü (Wavelet Transform)

ABSTRACT

Keywords: Brent Oil, Geopolitical Risk Index (GPR), Oil Volatility Index (OVX), Time Series Forecasting, Wavelet Transform

Crude oil prices, one of the most strategic components of global energy markets, exhibit a nonlinear structure influenced not only by supply-demand dynamics but also by financial volatility and geopolitical uncertainties. Particularly in recent years, global crises, wars, and market shocks have increased the importance of data-driven and advanced modeling approaches in oil price forecasting. In this study, the effects of the Oil Volatility Index (OVX) and the Geopolitical Risk Index (GPR) on Brent crude oil price forecasting were analyzed using machine learning algorithms.

The methodological framework of the study consists of dataset integration covering the period between 2014 and 2024, data preprocessing stages, signal processing techniques, and hybrid machine learning models. In order to reduce financial noise within the dataset, the Wavelet Transform method was applied. In addition, logarithmic transformation, winsorization, and Min-Max scaling techniques were employed. To improve model performance, feature engineering processes based on lag variables and Exponential Moving Average (EMA) indicators were also implemented.

Within the scope of the study, XGBoost, LSTM, and hybrid models were developed and evaluated using RMSE, MAE, MAPE, and R^2 performance metrics. The findings revealed that the hybrid model approach demonstrated stronger performance, particularly during periods of high volatility. The hybrid model achieved approximately 83% explanatory power (R^2) on the 2014–2024 test dataset while producing low error rates and successful prediction performance. Furthermore, on the out-of-sample test dataset covering the period between 2024 and 2026, the hybrid model reached an explanatory level of approximately 93%. One possible explanation for this improvement is that the volatility patterns observed during the 2024–2026 period appear to be more compatible with the structure learned from the training dataset.

In addition, the conducted volatility regime analysis, rolling forecast error analysis, and directional accuracy results indicated that the OVX index has a significant impact on Brent crude oil price forecasting performance.

Overall, the study demonstrates that hybrid machine learning approaches can generate strong predictive results in Brent crude oil forecasting and highlights the effectiveness of data-driven forecasting methodologies in financial time series analysis.

BÖLÜM 1. GİRİŞ

1.1. Küresel Ekonominin Kalbi: Ham Petrol Piyasaları

Ham petrol, modern ekonomilerin en kritik enerji girdilerinden biri olarak kabul edilmekte ve küresel ekonomik faaliyetler üzerinde önemli etkiler oluşturmaktadır. Ulaşım, petrokimya, üretim ve lojistik gibi birçok sektörün maliyet yapısı doğrudan veya dolaylı olarak petrol fiyatlarına bağlıdır. Bu nedenle petrol fiyatlarında meydana gelen değişimlerin ekonomik karar alma süreçleri üzerinde önemli etkiler oluşturduğu bilinmektedir. Özellikle enerji piyasalarında gözlenen yüksek oynaklık ve belirsizlik ortamı, petrol fiyatlarının doğru şekilde tahmin edilmesini hem işletmeler hem de politika yapıcılar açısından önemli hale getirmektedir (Xu vd., 2023).

Bununla birlikte ham petrol piyasaları yalnızca arz ve talep dengesi ile şekillenmemektedir. Finansal piyasalardaki belirsizlikler, jeopolitik gerilimler, savaşlar ve küresel krizler de petrol fiyatları üzerinde önemli etkiler oluşturabilmektedir. Alqahtani vd. (2020), jeopolitik riskler ile petrol fiyat hareketlerinin finansal piyasalar üzerindeki etkilerini incelemiş ve enerji odaklı ekonomilerde petrol piyasalarındaki oynaklığın ekonomik sistem üzerinde belirgin sonuçlar doğurabildiğini göstermiştir. Benzer şekilde Antonakakis vd. (2017), jeopolitik risklerin petrol ve finansal piyasalar arasındaki ilişkilerde önemli bir rol oynadığını ortaya koymuştur.

Literatürde petrol fiyatlarının doğrusal olmayan, yüksek volatiliteye sahip ve yapısal kırılmalardan etkilenen finansal zaman serileri olduğu belirtilmektedir. Bu nedenle geleneksel yöntemlerin yanında makine öğrenmesi ve derin öğrenme tabanlı yaklaşımlar giderek daha fazla kullanılmaktadır. Yiğit vd. (2021), Uzun Kısa Süreli Bellek (Long Term Short Memory, LSTM), modellerinin zaman serilerindeki uzun dönemli bağımlılıkları öğrenme konusunda başarılı sonuçlar üretebildiğini belirtirken, Xu vd. (2023) XGBoost gibi makine öğrenmesi algoritmalarının petrol fiyat tahminlerinde güçlü performans gösterebildiğini raporlamıştır. Ayrıca Lin vd. (2022), dalgacık dönüşümü ile derin öğrenme modellerini birleştiren hibrit yapıların tahmin doğruluğunu artırabildiğini göstermiştir.

Bu çalışma, Brent ham petrol fiyatlarının tahminlenmesinde yalnızca geçmiş fiyat hareketlerini değil, aynı zamanda Petrol Volatilite Endeksi (OVX) ve Jeopolitik Risk Endeksi (GPR) gibi dışsal değişkenleri de dikkate alan hibrit bir makine öğrenmesi yaklaşımı önermektedir. Çalışma kapsamında gelişmiş veri ön işleme teknikleri, sinyal işleme yöntemleri ve hibrit modelleme yapıları kullanılarak petrol piyasalarının karmaşık dinamiklerinin daha etkin şekilde analiz edilmesi amaçlanmaktadır.

1.2. Kurumsal Sürdürülebilirlik ve Stratejik Karar Alma Süreçlerinde Petrol Tahminlemesi

Ham petrol fiyatlarında meydana gelen dalgalanmalar, yalnızca makroekonomik göstergeler üzerinde değil, işletmelerin operasyonel ve finansal karar süreçleri üzerinde de etkiler oluşturmaktadır.

Petrol piyasalarının küresel ekonomiyle güçlü ilişkisi ve fiyat hareketlerinin belirsizlik unsurlarıyla birlikte şekillenmesi, petrol fiyat tahminlemesini işletmeler açısından önemli bir karar destek konusu haline getirmektedir. Alqahtani vd. (2020), petrol fiyatlarının özellikle petrol zengini Körfez İş birliği Konseyi (GCC) ülkelerindeki finansal piyasalar için önemli bir belirleyici olduğunu ve ham petrol getirilerinin borsa getirilerinin tahmininde dikkate alınması gerektiğini belirtmiştir.

Kurumsal perspektifte petrol fiyat tahminlemesinin önemi birkaç temel başlık altında değerlendirilebilir. İlk olarak enerji maliyetleri, üretim, lojistik ve tedarik zinciri süreçlerinde önemli bir maliyet unsuru olarak değerlendirilmektedir. Petrol fiyatlarında meydana gelen ani artışlar, işletmelerin maliyet planlaması, bütçe yönetimi ve yatırım kararları üzerinde baskı oluşturmaktadır. Bu nedenle enerji fiyatlarının yalnızca bir maliyet kalemi olarak değil, aynı zamanda stratejik bir finansal risk unsuru olarak ele alınması gerekmektedir (Liu vd., 2019). Ma vd. (2025), belirsizlik endekslerinin petrol piyasası volatilitésinin tahmininde bilgi sağlayabildiğini ve bu bilgilerin risk yönetimi ile yatırım kararları açısından önemli olduğunu vurgulamaktadır.

Bir diğer önemli unsur ise tedarik zinciri ve lojistik yönetimidir. Yakıt maliyetleri; taşımacılık, dağıtım ve depolama süreçlerinin temel gider kalemlerinden biri olduğu için petrol fiyatlarının öngörülebilmesi, işletmelerin lojistik maliyetlerini daha kontrollü yönetmesine katkı sağlayabilir. Özellikle yüksek belirsizlik dönemlerinde petrol fiyatı tahmin modelleri, rota planlama, navlun sözleşmelerinin zamanlanması, stok politikalarının belirlenmesi ve operasyonel bütçe yönetimi gibi süreçlerde karar destek aracı olarak kullanılabilir. Bu yaklaşım, petrol fiyatlarının yalnızca finansal piyasa değişkeni değil, aynı zamanda işletme operasyonlarını etkileyen stratejik bir girdi olduğunu göstermektedir.

Petrol fiyat tahminlemesinin önemli kullanım alanlarından biri de finansal riskten korunma ve yatırım kararlarıdır. Petrol piyasalarında jeopolitik riskler, savaşlar, bölgesel krizler ve piyasa volatilitési gibi dışsal faktörler ani fiyat değişimlerine neden olabilmektedir. Alqahtani vd. (2020), jeopolitik risk ile ham petrol fiyatlarının GCC finansal piyasaları açısından önemli tahmin değişkenleri olduğunu ortaya koyarken; Ma vd. (2025), belirsizlik göstergelerinin petrol piyasası volatilitésinin modellenmesinde kullanılabileceğini ve SHAP gibi açıklanabilir yapay zekâ yöntemlerinin risk faktörlerinin etkisini yorumlamaya katkı sağladığını belirtmiştir.

Bu bağlamda, yalnızca geçmiş fiyat hareketlerine dayalı tahminler yerine, dışsal risk göstergelerini de içeren veri odaklı yaklaşımlar daha kapsamlı sonuçlar sunabilmektedir. Çalışmada geliştirilen hibrit makine öğrenmesi yaklaşımı da bu bakış açısıyla tasarlanmıştır. Brent petrol fiyatları, OVX ve GPR değişkenleri birlikte kullanılarak işletmelerin belirsizlik altında daha veri odaklı, hızlı ve rasyonel kararlar alabilmesine katkı sağlayabilecek bir karar destek altyapısı oluşturulması amaçlanmıştır.

1.3. Literatür Taraması ve Teorik Çerçeve

Petrol fiyatlarının tahmini, küresel ekonominin en karmaşık ve çok değişkenli problemlerinden biri olarak kabul edilmektedir. Bu çalışma kapsamında incelenen 16 temel makale ve tez, literatürün gelişimini dört ana ekseninde (Belirsizlik Endeksleri, Pandemi Etkisi, Metodolojik Yenilikler ve Bölgesel Analizler) ortaya koymaktadır.

1.3.1. Volatilité ve Belirsizlik Endekslerinin Rolü (OVX ve GPR)

Finansal piyasalarda belirsizlik ve yatırımcı duyarlılığı, fiyat hareketlerinin yönü ve volatilitesi üzerinde önemli etkiler oluşturmaktadır. Özellikle enerji piyasalarında petrol fiyatlarının yalnızca arz-talep dinamiklerinden değil; aynı zamanda piyasa psikolojisi, küresel risk algısı ve jeopolitik gelişmelerden de güçlü şekilde etkilendiği literatürde yaygın olarak kabul edilmektedir. Bu nedenle son yıllarda OVX ve GPR, petrol fiyat tahminleme çalışmalarında önemli açıklayıcı değişkenler olarak kullanılmaya başlanmıştır.

OVX endeksi, petrol piyasalarındaki beklenen volatilitéyi ölçen ve yatırımcı korkusunu temsil eden önemli göstergelerden biri olarak değerlendirilmektedir. Shaikh (2019), OVX endeksi ile ham petrol fiyatları arasında negatif ve asimetrik bir ilişki bulunduğunu ortaya koymuş ve OVX'in yatırımcı duyarlılığını yansıtan bir "korku barometresi" işlevi gördüğünü belirtmiştir. Benzer şekilde Mazzeu vd. (2019), OVX endeksindeki volatilité hareketlerinin gelecekte oluşabilecek petrol fiyat şoklarının öngörülmesinde önemli bilgi taşıdığını ifade etmektedir. Dutta (2017) ise petrol piyasasındaki belirsizliğin yalnızca ham petrol fiyatlarını değil, temiz enerji piyasalarını da etkilediğini göstererek OVX'in enerji ekosistemi genelinde önemli bir gösterge olduğunu vurgulamıştır.

Jeopolitik risklerin petrol piyasaları üzerindeki etkileri literatürde yoğun şekilde incelenmiştir. Liu vd. (2019), ciddi jeopolitik olayların petrol vadeli işlem piyasalarında volatilitéyi artırabildiğini ve özellikle kriz dönemlerinde piyasa oynaklığının daha belirgin hale geldiğini belirtmiştir. Antonakakis vd. (2017) ise uzun dönemli çalışmalarında, jeopolitik risklerin petrol ve finansal piyasalar arasındaki ilişki üzerinde etkili olduğunu ve bu etkinin dönemsel koşullara bağlı olarak değişebildiğini ifade etmiştir. Bu çalışmalar, petrol fiyatlarının yalnızca ekonomik değişkenlerle değil, küresel risk ve belirsizlik unsurlarıyla birlikte değerlendirilmesi gerektiğini göstermektedir. Ekonomik büyüme ve

petrol piyasası dinamikleri üzerindeki etkilerini Çin ekonomisi perspektifinden analiz ederek GPR değişkeninin makroekonomik önemini ortaya koymuştur.

Literatürde elde edilen bulgular genel olarak değerlendirildiğinde, OVX ve GPR değişkenlerinin petrol fiyatlarındaki volatil hareketleri açıklamada önemli bilgi taşıdığı görülmektedir. Özellikle enerji piyasalarında petrol fiyatlarının yalnızca fiziksel arz ve talep koşulları tarafından değil, aynı zamanda yatırımcı beklentileri, piyasa belirsizliği ve jeopolitik riskler tarafından da şekillendiği birçok çalışmada ortaya konulmuştur (Antonakakis vd., 2017; Liu vd., 2019).

1.3.2. Pandemi ve Ekstrem Olayların Modelleme Üzerine Etkisi

Petrol piyasaları, küresel krizler ve ekstrem olaylar karşısında yüksek hassasiyet gösteren finansal yapılardan biridir. Özellikle COVID-19 pandemisi süreci, petrol fiyatlarında tarihsel ölçekte sert dalgalanmaların yaşanmasına neden olmuş ve finansal zaman serilerinde önemli yapısal kırılmalar oluşturmuştur. Pandemi döneminde küresel talebin ani şekilde daralması, üretim faaliyetlerinin yavaşlaması ve uluslararası lojistik ağlarının kesintiye uğraması; petrol piyasalarında alışılmış fiyat davranışlarının değişmesine yol açmıştır (Sharif vd., 2020; Kaymak ve Kaymak, 2022). Bu durum, geleneksel doğrusal modelleme yöntemlerinin performansını sınırlarken, veri odaklı ve adaptif makine öğrenmesi modellerine olan ilgiyi artırmıştır.

Literatürde COVID-19 süreci çoğunlukla yüksek belirsizlik ve yapısal kırılma dönemi olarak ele alınmaktadır. Tian vd. (2023), pandemi döneminde makine öğrenmesi modellerinin geleneksel yöntemlere kıyasla daha güçlü tahmin performansı gösterebildiğini, ancak model performanslarının dönemsel volatiliteye bağlı olarak dalgalanabildiğini belirtmiştir. Benzer şekilde Kaymak ve Kaymak (2022), pandemi dönemine ait gerçek piyasa verilerini kullanarak petrol fiyatlarının öngörülebilirliğini incelemiş ve kriz dönemlerinde veri temelli modellerin önemini arttığını vurgulamıştır.

Pandemi sürecinde yalnızca petrol fiyatları değil, finansal piyasalar, jeopolitik riskler ve yatırımcı davranışları arasındaki ilişkiler de daha karmaşık hale gelmiştir. Sharif vd. (2020), dalgacık tabanlı analiz yöntemi kullanarak COVID-19 süreci, petrol fiyatları, finansal piyasalar ve jeopolitik riskler arasındaki etkileşimi incelemiş; kriz dönemlerinde bu değişkenler arasındaki ilişkinin güçlendiğini ortaya koymuştur. Özellikle belirsizlik seviyesinin yükseldiği dönemlerde volatilitenin yapısının değişmesi, petrol fiyat tahmin modellerinin daha esnek ve adaptif yapılara ihtiyaç duymasına neden olmuştur.

Bu bağlamda pandemi, savaşlar ve küresel krizler gibi ekstrem olayların petrol fiyat tahminleme modelleri üzerinde doğrudan etkili olduğu görülmektedir. Çalışmada kullanılan hibrit makine öğrenmesi yaklaşımının temel motivasyonlarından biri de bu tür yüksek belirsizlik dönemlerinde ortaya çıkan karmaşık fiyat hareketlerini daha etkin şekilde modelleyebilmektir.

1.3.3. Metodolojik Yenilikler: Hibrit Modeller ve Sinyal İşleme

Finansal zaman serilerinde yer alan yüksek frekanslı gürültü ve ani volatil hareketler, model performansını doğrudan etkileyen temel problemler arasında yer almaktadır. Bu nedenle ham verilerin ön işleme süreçlerinden geçirilmesi ve sinyal ayrıştırma teknikleriyle desteklenmesi, modern petrol fiyat tahminleme çalışmalarında önemli bir yaklaşım haline gelmiştir. Özellikle Dalgacık Dönüşümü (Wavelet Transform) gibi sinyal işleme yöntemleri, finansal serilerdeki kısa dönemli gürültülerin azaltılmasına ve anlamlı örüntülerin daha net ortaya çıkarılmasına katkı sağlamaktadır.

Literatürde Lin vd. (2022), Wavelet Transform yöntemini BiLSTM-Attention-CNN mimarisi ile entegre ederek petrol fiyat tahmin performansında önemli iyileşmeler elde etmiştir. Çalışmada sinyal ayrıştırma yöntemlerinin, derin öğrenme modellerinin veri içerisindeki temel örüntüleri daha etkin öğrenmesine katkı sağlayabileceği belirtilmiştir. Ayrıca hibrit modelleme yaklaşımlarını inceleyen çalışmalar, veri ön işleme ve model entegrasyon tekniklerinin özellikle yüksek volatilitelere sahip zaman serilerinde tahmin başarısını artırabildiğini göstermektedir.

Makine öğrenmesi literatüründe hibrit modelleme yaklaşımlarının da giderek daha fazla önem kazandığı görülmektedir. Choudhary vd. (2025), hibrit modellerin tekil makine öğrenmesi algoritmalarına kıyasla daha düşük hata düzeyi ve daha yüksek tutarlılık değerleri üretebildiğini ortaya koymuştur. Benzer şekilde İftikhar vd. (2025) tarafından önerilen hibrit zaman serisi yaklaşımının, günlük petrol fiyatlarındaki volatil hareketleri yakalamada başarılı sonuçlar verdiği raporlanmıştır. Bu çalışmalar, farklı model yapılarını bir araya getiren hibrit yaklaşımların petrol fiyat tahmininde daha güçlü genelleme performansı sağlayabileceğini göstermektedir.

Bu doğrultuda çalışmada da veri ön işleme süreçleri, sinyal ayrıştırma teknikleri ve hibrit modelleme yaklaşımı birlikte kullanılarak Brent petrol fiyatlarının daha etkin şekilde tahminlenmesi amaçlanmıştır.

1.3.4. Makine Öğrenmesi ve Derin Öğrenme Uygulamaları

Derin öğrenme tabanlı modeller, finansal zaman serilerinde yer alan doğrusal olmayan ilişkileri ve karmaşık örüntüleri modelleme kapasitesi nedeniyle son yıllarda petrol fiyat tahminleme çalışmalarında yaygın şekilde kullanılmaktadır. Özellikle geleneksel ekonometrik yöntemlerin sınırlı kaldığı yüksek volatiliteler ve yapısal kırılma dönemlerinde, derin öğrenme modellerinin daha güçlü performans gösterebildiği literatürde sıkça vurgulanmaktadır.

Bu kapsamda Yiğit vd. (2021), LSTM tabanlı modellerin petrol fiyat serilerindeki uzun dönemli bağımlılıkları öğrenme konusunda başarılı sonuçlar üretebildiğini belirtmiştir. Çalışmada LSTM

mimarisinin, geçmiş zaman adımlarından gelen bilgiyi hafızasında tutabilme yeteneği sayesinde finansal zaman serilerindeki karmaşık ilişkileri daha etkin şekilde modelleyebildiği ifade edilmiştir.

Dikkat mekanizmasıyla desteklenen derin öğrenme modelleri de petrol fiyat tahminleme alanında önemli bir araştırma konusu haline gelmiştir. Wei (2026), Dikkat Mekanizmalı LSTM (Attention LSTM) yapısının enerji piyasalarındaki belirsizlik dönemlerinde modelin önemli zaman adımlarına odaklanmasını sağlayarak tahmin hata oranlarını azalttığını göstermiştir. Özellikle volatilité ve belirsizlik seviyesinin yükseldiği dönemlerde attention mekanizmasının model performansını iyileştirebildiği belirtilmiştir.

Petrol piyasalarındaki belirsizliklerin modellenmesi üzerine gerçekleştirilen çalışmalarda olasılıksal tahminleme yaklaşımları da dikkat çekmektedir. Shen vd. (2024), olasılıksal tahminleme yöntemleri kullanarak petrol piyasalarındaki belirsizlik yapısını incelemiş ve bu tür modellerin endüstriyel karar alma süreçlerinde önemli katkılar sağlayabileceğini ifade etmiştir.

Makine öğrenmesi ve ekonometrik modellerin karşılaştırıldığı çalışmalarda ise ağaç tabanlı algoritmaların öne çıktığı görülmektedir. Xu vd. (2023), geleneksel ekonometrik yöntemlerle modern makine öğrenmesi algoritmalarını karşılaştırmış ve özellikle XGBoost benzeri topluluk öğrenmesi tabanlı modellerin petrol fiyat tahmininde daha güçlü performans gösterebildiğini raporlamıştır. Bu durum, doğrusal olmayan ilişkileri modelleme kapasitesi yüksek olan makine öğrenmesi algoritmalarının enerji piyasalarında giderek daha fazla önem kazandığını göstermektedir.

Bu çalışmada da literatürdeki bu yaklaşımlar doğrultusunda XGBoost, LSTM ve hibrit model yapıları birlikte değerlendirilerek Brent petrol fiyatlarının tahmin performansının artırılması amaçlanmıştır.

1.3.5. Bölgesel ve Sektörel Analizler

Petrol fiyatlarındaki dalgalanmaların etkileri yalnızca küresel enerji piyasalarıyla sınırlı kalmamakta, aynı zamanda bölgesel finansal piyasalar ve ekonomik yapılar üzerinde de önemli sonuçlar oluşturmaktadır. Özellikle enerji ihracatçısı veya enerji ithalatına bağımlı ülkelerde petrol fiyat hareketlerinin ekonomik göstergeler üzerindeki etkileri literatürde geniş şekilde incelenmiştir.

Alqahtani vd. (2020), Körfez İş birliği Konseyi (GCC) ülkeleri üzerine gerçekleştirdikleri çalışmada, jeopolitik riskler ve petrol fiyat hareketlerinin borsa getirileri üzerindeki etkilerini analiz etmiştir. Çalışmada özellikle enerji odaklı ekonomilerde petrol fiyatlarındaki volatilitenin finansal piyasalar üzerinde belirgin etkiler oluşturduğu belirtilmiştir. Bu durum, petrol piyasalarındaki belirsizliklerin yalnızca enerji sektörünü değil, sermaye piyasalarını da doğrudan etkileyebildiğini göstermektedir.

Petrol fiyat tahminleme alanında son yıllarda farklı veri kaynaklarının birlikte kullanıldığı veri odaklı modelleme yaklaşımları önem kazanmaktadır. Özellikle finansal göstergeler, volatilité endeksleri ve jeopolitik değişkenlerin birlikte değerlendirilmesi; petrol piyasalarının karmaşık yapısının daha

kapsamlı biçimde modellenmesine katkı sağlayabilmektedir. Bu yaklaşım, petrol fiyatlarının yalnızca geçmiş fiyat hareketleri üzerinden değil, dışsal değişkenlerle birlikte ele alınmasının tahmin performansına olumlu katkılar sunabileceğini göstermektedir.

Literatürde petrol fiyat tahminleme performansının artırılmasında çok kaynaklı veri kullanımının önemli bir rol oynadığı vurgulanmaktadır. Petrol piyasaları; geçmiş fiyat hareketlerinin yanı sıra volatilité göstergeleri, jeopolitik riskler, finansal piyasalar ve makroekonomik faktörlerden etkilenen karmaşık bir yapıya sahiptir. Bu nedenle yalnızca geçmiş fiyat verilerine dayanan modeller yerine, farklı bilgi kaynaklarını bir araya getiren veri odaklı yaklaşımların daha kapsamlı sonuçlar üretebildiği belirtilmektedir. Özellikle volatilité ve belirsizlik göstergelerinin modele dahil edilmesi, petrol fiyatlarını etkileyen dışsal faktörlerin daha etkin biçimde temsil edilmesine katkı sağlamaktadır (Liu vd.,2019; Alqahtani vd.,2020)

Petrol fiyat tahminleme alanında kullanılan yöntemler oldukça geniş bir yelpazeye sahiptir. Literatürde ARIMA, GARCH ve VAR gibi geleneksel istatistiksel ve ekonometrik modellerin yanı sıra yapay sinir ağları, LSTM, evrimsel sinir ağları (CNN), hibrit derin öğrenme modelleri ve topluluk öğrenmesi yaklaşımlarının kullanıldığı çok sayıda çalışma bulunmaktadır (Lin vd., 2022; Xu vd., 2023; Choudhary vd., 2025). Farklı model yapılarının farklı veri setlerinde değişen performanslar göstermesi, petrol fiyat tahminleme probleminin doğrusal olmayan ve çok boyutlu bir yapıya sahip olduğunu ortaya koymaktadır.

Genel olarak değerlendirildiğinde, güncel literatürün petrol fiyat tahminlemesinde çok kaynaklı veri kullanımına, hibrit model yapılarına ve açıklanabilir yapay zekâ yaklaşımlarına yöneldiği görülmektedir. Özellikle geleneksel yöntemler ile makine öğrenmesi ve derin öğrenme modellerinin birlikte kullanıldığı hibrit yaklaşımların daha düşük hata düzeyleri ve daha yüksek tahmin hassasiyeti sağlayabildiği rapor edilmektedir (Tian vd., 2023; Choudhary vd., 2025).

1.3.6. Metodolojik Çerçeve ve Teknik Yaklaşımlar

Bu çalışmada, Brent petrol fiyatlarının tahminlenmesi amacıyla veriye dayalı ve hibrit bir modelleme yaklaşımı benimsenmiştir. Çalışmanın metodolojik altyapısı; sinyal işleme teknikleri ile makine öğrenmesi algoritmalarının birlikte kullanılmasına dayanmaktadır. İlk aşamada, finansal zaman serilerinde yaygın olarak karşılaşılan gürültü ve yüksek frekanslı volatilité problemlerinin azaltılması amacıyla Dalgacık Dönüşümü (Wavelet Transform) yöntemi uygulanmıştır. Daubechies (db4) ana dalgacığı kullanılarak gerçekleştirilen bu süreçte, veri serisi yakınsama ve detay bileşenlerine ayrıştırılmış; kısa dönemli anlamsız dalgalanmaların etkisi azaltılırken, pandemi, savaş ve jeopolitik krizler gibi yapısal kırılmaların korunması hedeflenmiştir.

Modelleme aşamasında ise doğrusal olmayan ilişkileri öğrenme kapasitesi yüksek olan XGBoost (Extreme Gradient Boosting) algoritması ile zaman serilerindeki uzun dönemli bağımlılıkları modelleyebilen LSTM mimarisi kullanılmıştır. XGBoost modeli özellikle özellikler arası karmaşık ilişkileri öğrenmede güçlü performans sunarken, LSTM modeli zaman bağımlı örüntüleri hafıza mekanizması aracılığıyla analiz edebilmektedir. Çalışmada ayrıca her iki modelin avantajlarını bir araya getirebilmek amacıyla hibrit model yaklaşımı geliştirilmiştir.

Makine öğrenmesi modellerinin daha stabil çalışabilmesi için veri ön işleme süreçleri uygulanmıştır. Bu kapsamda seriler üzerinde logaritmik dönüşüm, winsorizasyon ve Min-Maks ölçeklendirme işlemleri gerçekleştirilerek veri normalizasyonu sağlanmıştır. Özellik mühendisliğisürecinde ise gecikmeli değişkenler, hareketli ortalama göstergeleri (EMA) ve volatilité temelli türetilmiş değişkenler modele dahil edilmiştir. Ayrıca Petrol Volatilité Endeksi (OVX) ile Jeopolitik Risk Endeksi (GPR) değişkenleri, petrol piyasasındaki belirsizlik ve yatırımcı duyarlılığını temsil eden önemli açıklayıcı değişkenler olarak kullanılmıştır.

Çalışmada geliştirilen modellerin performansı; denklem 1, denklem 2, denklem 3 ve denklem 4 de verilen RMSE, MAE, MAPE ve 4 R² metrikleri üzerinden değerlendirilmiştir. Ek olarak volatilité rejim analizi, hareketli tahmin hatası analizi ve ortalama yönsel doğruluk analizleri gerçekleştirilerek modellerin farklı piyasa koşullarındaki davranışları incelenmiştir. Elde edilen sonuçlar, hibrit model yaklaşımının özellikle yüksek volatilité dönemlerinde daha güçlü tahmin performansı sunduğunu göstermektedir.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (1) \quad MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (2)$$

$$MAPE = \frac{100}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \quad (3) \quad R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (4)$$

- y_i : i'nci gözleme ait gerçek değer
- $\hat{y}_i$: i'nci gözleme ait tahmin edilen değer
- $\bar{y}$: Gerçek değerlerin ortalaması
- n : Gözlem sayısı

BÖLÜM 2. PROBLEMİN TANIMI

Günümüz küresel enerji piyasalarında ham petrol fiyatları, yalnızca arz-talep dengesi ile açıklanamayan, yüksek volatiliteye sahip ve çok boyutlu bir yapı sergilemektedir. Finansal piyasaların küreselleşmesiyle birlikte yatırımcı duyarlılığı, piyasa korkusu ve jeopolitik gelişmeler petrol fiyatlarının oluşumunda giderek daha belirleyici hale gelmiştir. Özellikle savaşlar, siyasi krizler, terör olayları ve küresel ekonomik belirsizlikler gibi dışsal faktörler, petrol fiyatlarında ani ve doğrusal olmayan hareketlere neden olabilmektedir.

Bu noktada ortaya çıkan temel problem, geleneksel tahminleme yöntemlerinin ve yalnızca geçmiş fiyat hareketlerine dayanan modellerin, dışsal şokların petrol fiyatları üzerindeki etkilerini yeterince açıklayamamasıdır. Özellikle 2014–2024 döneminde yaşanan pandemi süreci, Rusya-Ukrayna savaşı ve Orta Doğu merkezli jeopolitik gerilimler; petrol piyasalarında yüksek belirsizlik ortamı oluşturmuş ve fiyat hareketlerinin öngörülebilirliğini zorlaştırmıştır. Bu durum, petrol fiyat serilerinin yalnızca ekonomik göstergelerle değil, aynı zamanda volatilité ve jeopolitik risk faktörleriyle birlikte değerlendirilmesi gerektiğini ortaya koymaktadır.

İşletmeler açısından değerlendirildiğinde ise petrol fiyatlarındaki yüksek oynaklık; maliyet yönetimi, bütçe planlaması, tedarik zinciri yönetimi ve finansal riskten korunma süreçleri üzerinde doğrudan etkiler oluşturmaktadır. Petrol fiyat hareketlerinin doğru tahmin edilememesi, stratejik karar alma süreçlerinde belirsizliği artırarak işletmeler açısından önemli operasyonel riskler doğurabilmektedir. Bu nedenle çalışmanın temel problemi; petrol fiyatları ile jeopolitik risk ve piyasa volatilitesi arasındaki karmaşık ilişkinin veri odaklı yöntemlerle modellenmesi ve finansal zaman serilerindeki gerçek risk sinyallerinin daha etkin şekilde analiz edilmesidir.

BÖLÜM 3. PROBLEMİN ÇÖZÜMÜ İÇİN TAKİP EDİLECEK AŞAMALAR

Projenin uygulama aşaması, verinin ham halinden tahmin edilebilir bir sinyale dönüştürülmesini kapsayan yedi temel adımdan oluşan sistematik bir iş akışına dayanmaktadır. Sürecin ilk basamağında, farklı kaynaklardan elde edilen heterojen veriler (fiyat, endeks ve medya verileri) Python programlama dili ekosisteminde senkronize edilerek bütünsel bir veri seti oluşturulmuştur. Bu aşamayı takip eden keşifsel veri analizi süreciyle, jeopolitik şokların petrol fiyatları üzerindeki tarihsel izdüşümleri istatistiksel yöntemlerle doğrulanmıştır.

(Bu proje için kullanılan bilgisayarın ve ilgili kütüphanelerin bilgileri Tablo 1 de verilmiştir.)

Tablo 1 Sistem Bileşenleri

Bileşen	Özellik
İşlemci	Intel Core i7-10750H
Bellek	16 GB RAM
Ekran Kartı	NVIDIA GTX 1650
Programlama Dili	Python 3.11
Veri Analizi	Pandas 2.2.2, NumPy 1.26.4
Makine Öğrenmesi	Scikit-Learn 1.5.1, XGBoost 2.1.1
Derin Öğrenme	TensorFlow 2.18.0
Açıklanabilir Yapay Zeka	SHAP 0.46.0
Sinyal İşleme	PyWavelets 1.6.0

Çalışmanın en özgün teknik aşamasını, verideki günlük piyasa gürültülerini (noise) ana trendden ayırtıran Ayırık Dalgacık Dönüşümü (DWT) oluşturmaktadır. Bu yöntemle temizlenen veri seti, makine öğrenmesi modellerinin (XGBoost ve LSTM) matematiksel kararlılığına uygun hale getirilmesi için logaritmik dönüşüm ve ölçeklendirme işlemlerine tabi tutulmuştur. Özellik mühendisliği adımıyla, zaman serisinin geçmişe dönük hafızası modele "gecikmeli değişkenler" üzerinden aktarılmış; böylece jeopolitik bir krizin fiyatlara yansıma süresi (time-lag) analiz edilmiştir. Nihai aşamada, eğitilen modellerin performansları RMSE ve MAE gibi akademik geçerliliği olan hata metrikleriyle ölçülerek, projenin başlangıcında tanımlanan "doğru tahminleme" probleminin çözümü sayısal verilerle valide edilmiştir.

Tablo 2 Çözüm Aşamaları

Çözüm Aşamaları	Yapılan İş	Çözüm Aracı, Yöntem, Teknik, Program vs.
1	Veri Hazırlığı ve Entegrasyon	Python, Excel
2	Keşifsel Veri Analizi	Python
3	Sinyal İşleme ve Gürültü Arındırma	Dalgacık Dönüşümü
4	Veri Dönüştürme, Normalizasyon ve Winsorizasyon	Logaritmik Dönüşüm, Min-Maks Ölçeklemesi
5	Özellik Mühendisliği	Gecikmeli Değişken Analizi, Hareketli Ortalamalar
6	Modelleme ve Analiz	XGBoost, LSTM, Lineer Regresyon, RMSE, MAE, MAPE, R2

BÖLÜM 4. UYGULAMA

4.1. Veri Hazırlığı ve Entegrasyon

Bu çalışmada kullanılan veri seti, Brent ham petrol fiyatları ile Petrol Volatilite Endeksi (OVX) ve Jeopolitik Risk Endeksi (GPR) verilerinin bir araya getirilmesiyle oluşturulmuştur. Çalışmanın temel amacı, petrol fiyat hareketlerini yalnızca geçmiş fiyat davranışları üzerinden değil; aynı zamanda piyasa volatilitesi ve jeopolitik belirsizlik göstergeleri ile birlikte analiz edebilmektir. Bu nedenle farklı veri kaynaklarından elde edilen serilerin ortak bir zaman ekseninde entegre edilmesi çalışmanın ilk ve en kritik aşamalarından birini oluşturmaktadır.

Çalışmada Brent petrol fiyat verileri ile OVX verileri Yahoo Finance platformu üzerinden günlük frekansta elde edilmiştir (Yahoo Finance, 2026). Brent petrol fiyat serisinde kapanış fiyatları kullanılmıştır. OVX verisi ise petrol piyasalarındaki beklenen volatilitayı temsil eden önemli bir gösterge olarak modele dahil edilmiştir. Jeopolitik Risk Endeksi (GPR) ve GPR Threat verileri ise Matteo Iacoviello ve Dario Caldara tarafından yayımlanan veri setinden alınmıştır (Caldara ve Iacoviello, 2026). Veri setleri 2014–2024 dönemini kapsayacak şekilde hazırlanmış ve tüm seriler günlük frekansta analiz edilmiştir.

İlk aşamada tüm veri setleri Python ortamına aktarılmıştır. Veri setleri farklı kaynaklardan elde edildiği için tarih sütunları arasında format farklılıkları oluşmuştur. Bu nedenle veri entegrasyonu öncesinde tarih değişkenleri standart formata dönüştürülmüş ve veri setleri aynı zaman yapısına uygun hale getirilmiştir. Özellikle GPR veri setinde tarih sütununun farklı isimlendirilmesi nedeniyle veri yapısı yeniden düzenlenmiş ve zaman serileri ortak bir ekseninde hizalanmıştır.

Veri entegrasyonu sürecinde Brent petrol fiyatları, OVX, GPR ve GPR Threat değişkenleri tarih sütunu üzerinden birleştirilmiştir. Finansal piyasaların işlem günleri ile jeopolitik veri yayın sıklıkları birebir örtüşmediği için bazı tarihlerde eksik gözlemler oluşmuştur. Bu nedenle birleştirme işlemleri sonrasında veri seti üzerinde eksik veri kontrolleri gerçekleştirilmiş ve ortak tarih aralıkları korunarak analiz veri seti oluşturulmuştur. Böylece modellerin yalnızca eksiksiz gözlemler üzerinden eğitilmesi sağlanmıştır.

Birleştirme işlemi sonrasında veri seti üzerinde temel veri kalite kontrolleri uygulanmıştır. Bu kapsamda:

- eksik gözlem kontrolü,
- veri tipi doğrulamaları,
- tarih sıralaması kontrolleri,
- tekrar eden kayıtların incelenmesi,
- anormal değer gözlemleri gerçekleştirilmiştir.

Tablo 3 Veri Seti İlk 5 Satır

Date	Brent_Petrol (\$)	OVX (\$)	GPRD	GPRD_THREAT
02.01.2014	107.7799	20.24	82.1298	68.2935
03.01.2014	106.8899	20.60	117.9549	130.7776
06.01.2014	106.7300	20.70	103.5177	65.5834
07.01.2014	107.3488	19.67	91.5314	21.7461
08.01.2014	107.1500	20.17	93.8289	47.4914

Tablo 3 de oluşturulan veri setinin ilk 5 satırı verilmiştir.

Özellikle finansal zaman serilerinde veri bütünlüğü model performansı üzerinde doğrudan etkili olduğundan, veri hazırlık süreci dikkatli şekilde yürütülmüştür.

Veri setinin son hali oluşturulduktan sonra serilerin genel davranışları incelenmiştir. Brent petrol fiyatları, OVX ve GPR değişkenlerinin zaman içerisindeki hareketleri grafiksel olarak analiz edilmiştir. İnceleme sonucunda özellikle 2020 pandemi dönemi, 2022 Rusya-Ukrayna savaşı ve Orta Doğu merkezli jeopolitik gerilimlerin bulunduğu dönemlerde volatilitenin belirgin şekilde arttığı gözlemlenmiştir. Aynı dönemlerde OVX ve GPR değişkenlerinde de ani yükselişlerin olduğu görülmüş, bu durum ilgili değişkenlerin petrol fiyat hareketleri üzerinde açıklayıcı bilgi taşıyabileceğini göstermiştir.

4.2. Keşifsel Veri Analizi

Veri hazırlama ve entegrasyon süreçlerinin tamamlanmasının ardından, modelleme aşamasına geçmeden önce veri setinin genel yapısını anlayabilmek amacıyla keşifsel veri analizi (Exploratory Data Analysis- EDA) gerçekleştirilmiştir. Bu aşamada Brent petrol fiyatları, Petrol Volatilite Endeksi (OVX) ve Jeopolitik Risk Endeksi (GPR) değişkenlerinin zaman içerisindeki davranışları, birbirleriyle olan ilişkileri ve istatistiksel özellikleri incelenmiştir.

İlk olarak veri setinde yer alan değişkenlerin zaman serisi grafikleri oluşturulmuştur. Brent petrol fiyatlarının özellikle pandemi dönemi, Rusya-Ukrayna savaşı ve küresel jeopolitik gerilimlerin yoğunlaştığı dönemlerde yüksek volatilitate gösterdiği gözlemlenmiştir. Aynı dönemlerde OVX endeksinde ani yükselişler meydana gelirken, GPR endeksinde de belirgin sıçramalar olduğu görülmüştür. Bu durum, volatilitate ve jeopolitik risk değişkenlerinin petrol fiyat hareketleri üzerinde etkili olabileceğini göstermektedir.

Tablo 4 Tanımlayıcı İstatistikler

	Brent Petrol	OVX	GPRD	GPRD_THREAT
Veri Adeti	2512	2512	2512	2512
Ort	68,345	39,513	114,73	132,238
Std	21,092	19,676	52,901	72,954
Min	19,33	14,5	9,492	7,893
25%	51,818	29,317	80,333	85,85
Ortanca	65,3	36,595	105,53	118,926
75%	81,663	45,197	138,24	161,69
Maks	127,98	325,15	540,83	809,487
Çarpıklık	0,443	4,99	2,09	2,59
Basıklık	-0,419	42,184	9,168	14,448

Serilerin temel istatistiksel özelliklerini incelemek amacıyla Tablo 4'de verilen tanımlayıcı istatistik analizi gerçekleştirilmiştir. Ortalama, standart sapma, minimum, maksimum ve çeyreklik değerler incelendiğinde Brent petrol fiyat serisinin geniş bir fiyat aralığında hareket ettiği görülmektedir. Özellikle OVX serisinin yüksek standart sapma değerine sahip olması, piyasa korkusu ve belirsizlik seviyesinin dönemsel olarak önemli değişimler gösterdiğine işaret etmektedir. GPR ve GPR Threat serilerinde ise ortalama ve maksimum değerler arasındaki büyük farklar, belirli kriz dönemlerinde olağanüstü yükselişlerin meydana geldiğini göstermektedir.

Çarpıklık ve basıklık değerleri incelendiğinde, Brent petrol fiyat serisinin 0,443 çarpıklık değeri ile hafif sağa çarpık bir dağılım sergilediği, basıklık değerinin ise -0,419 olması nedeniyle normal dağılıma yakın ancak daha basık bir yapıya sahip olduğu görülmektedir. Buna karşılık OVX serisinin 4,99 çarpıklık ve 42,184 basıklık değerlerine sahip olması, dağılımın aşırı sağa çarpık olduğunu ve ekstrem gözlemler içerdiğini göstermektedir. Benzer şekilde GPR ve GPR Threat serilerinin sırasıyla 2,09 ve 2,59 çarpıklık değerleri ile pozitif yönde çarpık dağıldığı, yüksek basıklık değerlerinin (9,168 ve 14,448) ise bu serilerde olağanüstü jeopolitik olaylar nedeniyle uç değerlerin bulunduğu işaret ettiği söylenebilir. Bu sonuçlar, volatilité ve jeopolitik risk göstergelerinin normal dağılımdan önemli ölçüde sapmalar gösterdiğini ve finansal zaman serilerinde sıkça görülen ani şokları yansıttığını ortaya koymaktadır.

Keşifsel analiz kapsamında değişkenler arasındaki ilişkileri incelemek amacıyla korelasyon analizi gerçekleştirilmiştir. Brent petrol fiyatları ile OVX arasında genel olarak negatif yönlü bir ilişki


gözlemlenirken, GPR değişkeni ile petrol fiyatları arasındaki ilişkinin dönemsel olarak değişebildiği görülmüştür. Özellikle yüksek belirsizlik dönemlerinde volatilité endekslerinin petrol fiyat hareketleri üzerindeki etkisinin daha belirgin hale geldiği değerlendirilmiştir.

Bu aşamada veri setindeki aykırı gözlemler ve ani sıçramalar da incelenmiştir. Finansal zaman serilerinin doğası gereği veri setinde yüksek frekanslı gürültü ve ekstrem hareketler bulunduğu görülmüştür. Özellikle COVID-19 süreci sırasında petrol fiyatlarında sert düşüşler yaşandığı, aynı dönemde OVX endeksinin önemli ölçüde yükseldiği gözlemlenmiştir. Benzer şekilde savaş ve jeopolitik kriz dönemlerinde GPR serisinde ani artışlar meydana gelmiştir.

Gerçekleştirilen keşifsel veri analizi sonucunda:

- veri setinin yüksek volatilité içerdiği,
- değişkenler arasında doğrusal olmayan ilişkiler bulunduğu,
- piyasa şoklarının seriler üzerinde belirgin etkiler oluşturduğu,
- veri ön işleme ve sinyal arındırma süreçlerinin gerekli olduğu değerlendirilmiştir.

Bu bulgular doğrultusunda bir sonraki aşamada veri seti üzerinde sinyal işleme ve gürültü arındırma işlemleri uygulanmıştır.




Şekil 1. Brent Petrol, OVX ve GPR Değişkenlerinin Zaman Serisi Grafiği

Şekil 1 incelendiğinde Brent petrol fiyatı, OVX ve GPR serilerinin belirli dönemlerde eş zamanlı hareketler sergilediği görülmektedir. Özellikle 2020 pandemi dönemi ve 2022 jeopolitik kriz sürecinde, OVX ve GPR değişkenlerinde ani artışlar meydana gelirken Brent petrol fiyatlarında da sert kırılmalar gözlemlenmiştir. Bu durum, petrol fiyatlarının yalnızca geçmiş fiyat hareketlerinden değil, piyasa volatilitesi ve jeopolitik risk unsurlarından da etkilenebildiğini göstermekte ve dışsal değişkenlerin modele dahil edilmesinin önemini desteklemektedir.

4.3. Sinyal İşleme ve Gürültü Arındırma

Finansal zaman serileri, yüksek frekanslı dalgalanmalar ve rastgele gürültüler içeren karmaşık yapılardır. Özellikle petrol fiyatları gibi volatilitesi yüksek finansal serilerde, kısa dönemli anlamsız hareketler model performansını olumsuz etkileyebilmekte ve gerçek piyasa davranışlarının öğrenilmesini zorlaştırabilmektedir. Bu nedenle modelleme aşamasından önce veri seti üzerinde sinyal işleme ve gürültü arındırma işlemleri gerçekleştirilmiştir.



Şekil 2. GPRD İçin Dalgacık Dönüşümü Gösterimi

Çalışmada gürültü azaltma amacıyla Dalgacık Dönüşümü (Wavelet Transform) yöntemi kullanılmıştır. Wavelet yöntemi, finansal zaman serilerini farklı frekans bileşenlerine ayırarak veri içerisindeki kısa dönemli gürültüleri azaltabilmekte ve temel eğilimlerin daha net şekilde ortaya çıkarılmasına yardımcı olmaktadır. Bu kapsamda Daubechies ailesine ait db4 ana dalgacığı tercih edilmiştir.

İlk aşamada Brent petrol fiyat serisi, OVX ve GPR değişkenleri wavelet dönüşümüne tabi tutulmuştur. Dönüşüm işlemi sırasında seriler yakınsama ve detay bileşenlerine ayrıştırılmıştır. Yakınsama bileşenleri serinin genel trend yapısını temsil ederken, detay bileşenleri kısa dönemli yüksek frekanslı hareketleri ifade etmektedir. Gürültü azaltma sürecinde belirli detay bileşenleri baskılanarak seriler yeniden oluşturulmuştur.

Şekil 2’de görüldüğü üzere uygulanan dönüşüm işlemi sonrasında veri setindeki yüksek frekanslı dalgalanmaların azaltıldığı ve serinin daha düzgün bir yapı kazandığı gözlemlenmiştir. Bununla birlikte pandemi süreci, savaş dönemleri ve jeopolitik krizler gibi gerçek piyasa şoklarını temsil eden büyük hareketlerin korunmasına dikkat edilmiştir. Böylece modelin finansal gürültü yerine piyasanın temel yapısal davranışlarını öğrenebilmesi hedeflenmiştir.

Wavelet dönüşümü sonrasında oluşturulan yeni değişkenler:

- Price_clean
- OVX_clean
- GPRD_clean
- GPRD_THREAT_clean şeklinde veri setine eklenmiştir.

Modelleme sürecinde ham veriler yerine bu gürültü azaltılmış seriler kullanılmıştır. Gerçekleştirilen incelemelerde, wavelet dönüşümü sonrası serilerin daha stabil hale geldiği ve ani mikro dalgalanmaların azaldığı görülmüştür. Özellikle Brent petrol fiyat serisinin dönüşüm öncesi ve sonrası karşılaştırıldığında, temel trend yapısının korunduğu ancak yüksek frekanslı oynaklıkların azaltıldığı gözlemlenmiştir. Bu durum, makine öğrenmesi modellerinin daha anlamlı örüntüler öğrenmesine katkı sağlamıştır.

Tablo 5 Dalgacık Dönüşümü Sonrası Karşılaştırma

Tarih	Brent_Petrol (Önce)	Brent_Petrol (Sonra)	GPRD (Önce)	GPRD (Sonra)	GPRD_THREAT (Önce)	GPRD_THREAT (Sonra)
02.01.2014	107.78	107.425	82.130	103.555	68.293	59.502
03.01.2014	106.89	106.633	117.955	94.152	130.778	90.442
06.01.2014	106.73	106.894	103.518	84.082	65.583	86.177
07.01.2014	107.35	106.339	91.531	76.265	21.746	82.655
08.01.2014	107.15	106.952	93.829	71.129	47.491	80.011


Tablo 5 incelendiğinde Wavelet dönüşümü sonrasında serilerin genel eğilim yapısının korunduğu, ancak kısa dönemli dalgalanmaların yeniden düzenlendiği görülmektedir. Dönüştürme işlemi sonrasında bazı gözlemlerde değerlerin azaldığı, bazı gözlemlerde ise arttığı gözlenmiştir. Bu durum yöntemin veri noktalarını doğrudan azaltma amacı taşımamasından kaynaklanmaktadır.

4.4. Veri Dönüştürme ve Normalizasyon

Sinyal işleme ve gürültü arındırma işlemlerinin ardından, makine öğrenmesi modellerinin daha stabil ve verimli çalışabilmesi amacıyla veri dönüştürme ve normalizasyon süreçleri uygulanmıştır. Finansal zaman serilerinde değişkenlerin farklı ölçeklerde ve yüksek volatilitelere sahip olması, model eğitim sürecini doğrudan etkileyebilmektedir. Bu nedenle modelleme öncesinde veri seti belirli dönüşüm işlemlerinden geçirilmiştir.

İlk olarak veri setindeki değişkenlerin dağılımları incelenmiştir. Brent petrol fiyatları ve volatilité endekslerinde belirli dönemlerde aşırı yükseliş ve düşüşler bulunduğu gözlemlenmiştir. Özellikle pandemi süreci ve jeopolitik kriz dönemlerinde oluşan ani sıçramalar, veri dağılımında çarpıklık oluşturmuştur. Bu durumun model performansı üzerindeki olumsuz etkilerini azaltmak amacıyla logaritmik dönüşüm işlemi uygulanmıştır.

Log dönüşümü sayesinde veri setindeki büyük ölçekli hareketler daha dengeli hale getirilmiş ve serilerin dağılım yapısı normalize edilmeye çalışılmıştır.



Şekil 3 Logaritmik Dönüşüm Grafiği

Şekil 3'te GPR, GPR Threat ve OVX değişkenlerinin log dönüşümü ve winsorizasyon işlemleri öncesi ve sonrası dağılımları gösterilmektedir. Dönüşüm öncesinde üç değişkende de sağa çarpık bir dağılım yapısı bulunduğu ve özellikle yüksek değerlerde uç gözlemlerin olduğu görülmektedir. Bu durum, finansal zaman serilerinde ve risk endekslerinde kriz dönemlerinde ortaya çıkan ani sıçramaların doğal bir sonucudur.

GPR değişkeni incelendiğinde, dönüşüm öncesinde gözlemlerin büyük bölümünün belirli bir aralıkta yoğunlaştığı, buna karşın bazı dönemlerde 400–500 seviyelerine ulaşan yüksek uç değerlerin

bulunduğu görülmektedir. Log dönüşümü sonrasında bu yüksek değerlerin etkisi azaltılmış ve dağılım daha dengeli bir yapıya yaklaşmıştır.

GPR Threat değişkeninde de benzer şekilde dönüşüm öncesinde belirgin sağa çarpıklık ve yüksek uç değerler gözlemlenmektedir. Özellikle jeopolitik tehdit algısının arttığı kriz dönemlerinde endeks değerleri olağan seviyelerin üzerine çıkmaktadır. Dönüşüm sonrasında bu aşırı değerlerin baskılandığı ve dağılımın daha kontrollü hale geldiği görülmektedir.

OVX değişkeni ise dönüşüm öncesinde oldukça sağa çarpık bir dağılım göstermektedir. Gözlemlerin büyük kısmı düşük ve orta volatilité seviyelerinde toplanırken, piyasa korkusunun arttığı dönemlerde yüksek OVX değerleri oluşmuştur. Log dönüşümü ve winsorizasyon işlemleri sonrasında OVX dağılımı daha simetrik ve modelleme için daha uygun bir yapıya yaklaşmıştır.

Bu çalışmada öncelikle değişkenlere logaritmik dönüşüm uygulanmıştır. Log dönüşümü denklem 5'teki şekilde ifade edilmektedir:

$$x' = \log(1 + x) \quad (5)$$

Burada x ham değişken değerini, x' ise logaritmik dönüşüm sonrası elde edilen değeri göstermektedir. $\log(1 + x)$ dönüşümünün tercih edilmesinin nedeni, sıfıra yakın değerlerde tanımsızlık problemini önlemek ve yüksek değerlerin dağılım üzerindeki baskın etkisini azaltmaktır.

Log dönüşümünün ardından uç değerlerin model üzerindeki etkisini azaltmak amacıyla winsorizasyon işlemi uygulanmıştır. Winsorizasyon, belirlenen alt ve üst eşik değerlerinin dışında kalan gözlemlerin silinmesi yerine eşik değerlerine çekilmesi işlemidir. Bu çalışmada özellikle üst uç değerlerin etkisini azaltmak amacıyla üst %1'lik dilimde winsorizasyon uygulanmıştır.

Winsorizasyon işlemi genel olarak denklem 6 'daki şekilde ifade edilmektedir:

$$x_i^w = \min(x_i, q_{0.99}) \quad (6)$$

Burada;

- x_i^w : Winsorizasyon işlemi sonrası elde edilen düzeltilmiş gözlem değeri
- x_i : Orijinal gözlem değeri
- $q_{0.99}$: İlgili değişkenin %99 persentil (yüzdelik dilim) değeri
- $\min(\cdot)$: İki değer arasından küçük olanı seçen fonksiyonu ifade etmektedir

Denklemden, gözlem değeri x_i %99 persentil değerinden küçük veya eşitse olduğu gibi korunmakta, %99 persentil değerinden büyükse $q_{0.99}$ değerine eşitlenmektedir. Böylece veri setindeki üst uç değerlerin etkisi azaltılarak modelleme sürecinde daha dengeli bir veri dağılımı elde edilmektedir.

Gerçekleştirilen log dönüşümü ve winsorizasyon işlemleri sonucunda, GPR, GPR Threat ve OVX değişkenlerinde uç değerlerin etkisi azaltılmış, dağılımlar daha dengeli hale getirilmiş ve modelleme

sürecinde değişkenlerin daha kararlı şekilde öğrenilmesi sağlanmıştır. Bu dönüşüm özellikle LSTM gibi ölçek ve dağılım hassasiyeti yüksek modeller için daha uygun bir veri yapısı oluşturmuştur.

Veri dönüştürme sürecinin son aşamasında denklem 7'deki Min-Maks normalizasyonu uygulanmıştır. Bu yöntem ile değişkenler ortak bir ölçeğe taşınarak farklı büyüklüklerdeki değişkenlerin model üzerindeki etkilerinin dengelenmesi amaçlanmıştır. Özellikle LSTM gibi gradyan tabanlı derin öğrenme modellerinde değişkenlerin farklı ölçeklerde olması öğrenme performansını olumsuz etkileyebilmektedir. Bu nedenle tüm değişkenler $[0, 1]$ aralığına dönüştürülerek modelleme sürecine uygun hale getirilmiştir.

$$x_{norm} = \frac{x - x_{min}}{x_{max} - x_{min}} \quad (7)$$

Burada;

- x_{norm} : Normalize edilmiş değer
- x : Orijinal gözlem değeri
- x_{min} : İlgili değişkenin minimum değeri
- x_{max} : İlgili değişkenin maksimum değeri

Veri sızıntısını önlemek amacıyla Min-Maks ölçeklendirme parametreleri yalnızca eğitim veri seti üzerinde hesaplanmış, daha sonra aynı parametreler doğrulama ve test veri setlerine uygulanmıştır.

4.5. Özellik Mühendisliği

Veri ön işleme ve normalizasyon süreçlerinin tamamlanmasının ardından, model performansını artırmak amacıyla özellik mühendisliği çalışmaları gerçekleştirilmiştir. Finansal zaman serilerinde yalnızca mevcut gün verilerinin kullanılması çoğu zaman yeterli olmamakta; geçmiş dönem hareketlerinin ve trend yapılarının modele aktarılması gerekmektedir. Bu nedenle çalışmada petrol fiyatları, volatilité ve jeopolitik risk değişkenleri üzerinden yeni türetilmiş değişkenler oluşturulmuştur. İlk olarak gecikmeli değişkenler oluşturulmuştur. Finansal piyasalar geçmiş fiyat hareketlerinden etkilenebildiği için Brent petrol fiyatları, OVX ve GPR değişkenlerinin belirli gecikmeli değerleri modele dahil edilmiştir. Bu kapsamda ilgili seriler için farklı zaman adımlarına ait gecikme yapıları oluşturulmuş ve geçmiş dönem bilgileri modele aktarılmıştır. Özellikle petrol fiyatlarının kısa vadeli momentum etkilerini taşıdığı gözlemlendiğinden, gecikme değişkenlerinin model performansına önemli katkı sağladığı görülmüştür. Böylece modellerin yalnızca mevcut günü değil, geçmiş günlere ait hareketleri de değerlendirebilmesi sağlanmıştır.

Gecikme değişkenlerine ek olarak üstel hareketli ortalama (Exponential Moving Average- EMA) tabanlı özellikler oluşturulmuştur. EMA yapıları, finansal serilerde trend yönünün daha stabil şekilde izlenmesine yardımcı olmaktadır. Bu kapsamda Brent petrol fiyatları ve volatilité değişkenleri

üzerinde farklı pencere uzunluklarında EMA hesaplamaları gerçekleştirilmiştir. Özellikle kısa dönemli EMA yapılarının piyasa yön değişimlerini daha hızlı yakalayabildiği gözlemlenmiştir. Özellik mühendisliği sürecinde ayrıca hedef değişken ile giriş değişkenleri arasındaki zaman hizalaması dikkatli şekilde gerçekleştirilmiştir. Özellikle LSTM modelinde kullanılan pencereleme (windowing) yapısı nedeniyle veri setinde kaymalar olduğu için eğitim, doğrulama ve test veri setleri yeniden hizalanmıştır. Böylece modellerin geleceğe ait bilgileri görmesi engellenmiş ve veri sızıntısı problemi önlenmiştir.

Tablo 6 Özellik Mühendisliğinde Oluşturulan Özellikler

Özellik Grubu	Açıklama	Amaç
Target	Bir sonraki gün brent petrol fiyatı	Tahmin hedefi
Price_Lag1-5	Brent petrol geçmiş 1-5 gün değerleri	Geçmiş fiyat etkisi
GPR_Lag1-5	GPRD geçmiş 1-5 gün değerleri	Risk gecikme etkisi
GPR_THREAT_Lag1-5	GPRD_THREAT geçmiş 1-5 gün değerleri	Tehdit gecikme etkisi
OVX_Lag1-5	OVX geçmiş 1-5 gün değerleri	Volatilite gecikme etkisi
Price_EMA5	Brent petrol 5 günlük EMA	Kısa dönem trend
Price_EMA20	Brent petrol 20 günlük EMA	Uzun dönem trend
GPR_EMA5	GPRD 5 günlük EMA	Kısa dönem risk eğilimi
GPR_EMA20	GPRD 20 günlük EMA	Uzun dönem risk eğilimi
GPR_THREAT_EMA5	GPRD_THREAT 5 günlük EMA	Kısa dönem tehdit eğilimi
GPR_THREAT_EMA20	GPRD_THREAT 20 günlük EMA	Uzun dönem tehdit eğilimi
OVX_EMA5	OVX 5 Günlük EMA	Kısa dönem volatilite eğilimi
OVX_EMA20	OVX 20 günlük EMA	Uzun dönem volatilite eğilimi

Tablo 6’da oluşturulan tüm özellikler detaylı şekilde açıklanmaktadır.

Gerçekleştirilen özellik mühendisliği çalışmaları sonucunda veri seti yalnızca ham fiyat hareketlerinden oluşan bir yapıdan çıkarılarak:

- geçmiş bağımlılıkları taşıyan,
- trend bilgisini içeren,


- volatilité davranışlarını temsil eden,
- jeopolitik risk etkilerini barındıran çok boyutlu bir veri yapısına dönüştürülmüştür.

Bu durum özellikle XGBoost ve hibrit model performansında belirgin iyileşmeler sağlamıştır.

Brent petrol fiyat serisinin zamansal bağımlılık yapısını incelemek amacıyla Otokorelasyon Fonksiyonu (Autocorrelation Function - ACF) analizi gerçekleştirilmiştir. ACF analizi, bir zaman serisinin mevcut değerleri ile geçmiş dönem değerleri arasındaki doğrusal ilişkiyi ölçmek amacıyla kullanılan temel zaman serisi analiz yöntemlerinden biridir. ACF katsayısı denklem 8 ile hesaplanmaktadır:

$$\rho_k = \frac{\sum_{t=k+1}^n (y_t - \bar{y})(y_{t-k} - \bar{y})}{\sum_{t=1}^n (y_t - \bar{y})^2} \quad (8)$$

Burada ρ_k k gecikmesindeki otokorelasyon katsayısını, (y_t) t anındaki gözlem değerini, $\bar{y}$ serinin ortalamasını ve (k) gecikme sayısını ifade etmektedir.



Şekil 4 Brent Petrol Fiyatını Otokorelasyon Grafiği

Şekil 4'te sunulan ACF grafiği incelendiğinde, Brent petrol fiyat serisinin ilk gecikmelerde 1'e oldukça yakın otokorelasyon değerleri sergilediği görülmektedir. Gecikme sayısı arttıkça korelasyon katsayılarında kademeli bir azalma meydana gelmesine rağmen, 30. gecikmeye kadar yüksek korelasyon yapısının devam ettiği gözlemlenmiştir. Bu sonuç, Brent petrol fiyatlarının güçlü bir zamansal bağımlılık içerdiğini ve geçmiş dönem fiyat bilgilerinin gelecekteki fiyat hareketleri

hakkında önemli bilgiler taşıdığını göstermektedir. Elde edilen bulgular, çalışmada kullanılan gecikmeli değişkenler (Lag) ve hareketli ortalama (EMA) tabanlı özelliklerin modele dahil edilmesini desteklemektedir.

ACF analizinde gözlemlenen yüksek korelasyon değerleri ilk bakışta veri sızıntısı şüphesi oluşturabilmektedir. Ancak bu çalışmada kullanılan Price_Lag1, Price_Lag5, EMA5 ve EMA20 gibi değişkenler yalnızca geçmiş dönem gözlemlerinden oluşturulmuş olup herhangi bir geleceğe ait bilgi içermemektedir. Ayrıca veri ön işleme ve normalizasyon aşamalarında tüm dönüşüm parametreleri yalnızca eğitim veri seti üzerinde hesaplanmış ve aynı parametreler doğrulama ile test veri setlerine uygulanmıştır. Bu nedenle yüksek korelasyon değerleri veri sızıntısından değil, Brent petrol fiyat serisinin güçlü otokorelasyon ve trend yapısından kaynaklanmaktadır.

Serinin durağanlık yapısını incelemek amacıyla ayrıca Genişletilmiş Dickey-Fuller Testi (Augmented Dickey-Fuller, ADF) testi uygulanmıştır. ADF testi aşağıdaki regresyon modeli üzerine kurulmaktadır:

H_0 : Seri birim kök içermektedir (durağan değildir)

H_1 : Seri birim kök içermemektedir (durağandır)

Tablo 7 ADF Test Sonuçları

ADF İstatistiği	-2,382
p-değeri	0,147
Kullanılan Gecikme Sayısı	15
Gözlem Sayısı	2490
Kritik Değerler	
1%	-3,433
5%	-2,863
10%	-2,567

Tablo 7’de verilen ADF testi sonucunda ADF istatistiği -2,382 ve p-değeri 0,147 olarak hesaplanmıştır. Elde edilen p-değerinin %5 anlamlılık düzeyinden büyük olması nedeniyle sıfır hipotezi reddedilememiş ve Brent petrol fiyat serisinin durağan olmadığı sonucuna ulaşılmıştır. Bu sonuç, ACF analizinde gözlemlenen yüksek ve yavaş azalan otokorelasyon yapısı ile uyumludur. Durağan olmayan serilerde geçmiş değerler ile mevcut değerler arasında güçlü ilişkiler gözlemlenebilmekte ve bu durum yüksek korelasyon katsayılarının oluşmasına neden olabilmektedir.

Sonuç olarak ACF ve ADF analizlerinden elde edilen bulgular birlikte değerlendirildiğinde, Brent petrol fiyat serisinin güçlü zamansal bağımlılık ve durağan olmama özellikleri taşıdığı görülmektedir. Bu nedenle çalışmada gecikmeli değişkenler ve hareketli ortalama tabanlı özellikler kullanılmış, aynı zamanda Wavelet dönüşümü, logaritmik dönüşüm ve normalizasyon gibi veri dönüştürme yöntemleri uygulanarak modeller için daha uygun bir veri yapısı oluşturulmuştur.

4.6. Modelleme ve Analiz

XGBoost Modeli

Makine öğrenmesi aşamasında ilk model olarak XGBoost (Extreme Gradient Boosting) algoritması kullanılmıştır. XGBoost, karar ağaçları tabanlı bir ensemble learning yöntemi olup özellikle doğrusal olmayan ilişkileri modelleme, yüksek boyutlu veri yapılarıyla çalışabilme ve aşırı öğrenmeyi kontrol altında tutabilme özellikleri nedeniyle finansal zaman serilerinde yaygın şekilde tercih edilmektedir (Choudhary vd., 2025). Petrol fiyatları gibi yüksek volatilitelere sahip ve çok sayıda dışsal faktörden etkilenen veri yapılarında, değişkenler arasındaki karmaşık ilişkilerin öğrenilebilmesi açısından güçlü bir yöntem olarak değerlendirilmiştir.

Model giriş değişkenleri olarak; gürültüden arındırılmış Brent fiyat serileri, OVX, GPR, GPR Threat değişkenleri, gecikmeli değişkenler (lag features) ve EMA tabanlı özellikler kullanılmıştır. Hedef değişken ise bir sonraki zaman adımıdaki Brent petrol fiyatı olacak şekilde oluşturulmuştur. Veri seti zaman serisi yapısı korunarak eğitim (%70), doğrulama (%15) ve test (%15) olmak üzere kronolojik biçimde ayrılmıştır. Veri ayrıştırma sürecinde rastgele karıştırma işlemi uygulanmamış ve geleceğe ait bilgilerin eğitim aşamasında modele aktarılması engellenmiştir.

İlk aşamada varsayılan parametrelerle temel bir XGBoost modeli oluşturulmuş ve model performansı değerlendirilmiştir. Elde edilen ilk sonuçlar modelin genel fiyat hareketlerini öğrenebildiğini ancak özellikle yüksek volatiliteli dönemlerinde hata seviyelerinin yüksek kaldığını göstermiştir. Başlangıç modelinde $RMSE = 6.35$ dolar, $MAE = 5.67$ dolar, $MAPE = \%6.50$ ve $R^2 = 0.3823$ değerleri elde edilmiştir.

Bu sonuçlar modelin Brent petrol fiyat hareketlerinin genel yönünü öğrenebildiğini ancak fiyat değişimlerinin önemli bir bölümünü açıklamakta yetersiz kaldığını göstermektedir. Özellikle düşük R^2 değeri ve yüksek hata oranları, modelin günlük fiyat değişimlerini yeterli hassasiyetle takip edemediğini ortaya koymuştur. Bu nedenle model performansını iyileştirmek amacıyla hiperparametre optimizasyon sürecine geçilmiştir.

Tablo 8 XGBoost Hiperparametre Havuzu

n_estimators	[500, 800, 1000, 1500, 2000]
learning_rate	[0.005, 0.01, 0.02, 0.03, 0.05]
max_depth	[2, 3, 4, 5, 6]
subsample	[0.7, 0.8, 0.9, 1.0]
colsample_bytree	[0.7, 0.8, 0.9, 1.0]
reg_alpha	[0, 0.001, 0.01, 0.05, 0.1]
reg_lambda	[1, 3, 5, 7, 10]
gamma	[0, 0.01, 0.05, 0.1, 0.3]

Optimizasyon sürecinde XGBoost modelinin performansını doğrudan etkileyen parametreler sistematik şekilde değerlendirilmiştir. Bu kapsamda; n_estimators, learning_rate, max_depth, subsample, colsample_bytree, reg_alpha, reg_lambda, gamma parametreleri üzerinde Tablo 8’de verilen havuz değerleri test edilmiştir. Amaç, modelin aşırı öğrenme eğilimini azaltmak ve farklı piyasa koşullarında daha güçlü genelleme performansı elde etmektir.

Gerçekleştirilen optimizasyon sonucunda en başarılı parametre kombinasyonu;

Subsample = 1.0, reg_lambda = 5, reg_alpha = 0, n_estimators = 1500, max_depth = 2, learning_rate = 0.02, gamma = 0, colsample_bytree = 0.7 değerleri ile elde edilmiştir.

En iyi hiperparametre değerleri ile optimize edilen modelin sonuçları Tablo 9’da verilmiştir.

Optimize edilen model ilk olarak doğrulama veri seti üzerinde değerlendirilmiştir. Doğrulama sonuçlarında modelin önemli ölçüde geliştiği görülmüştür:

Tablo 9 Optimize Edilmiş XGBoost Sonuçları

	Doğrulama	Test
RMSE	5.84 \$	3.72 \$
MAE	3.45 \$	2.65 \$
MAPE	%3.45	%2.90
R ²	0.9006	0.7872


Özellikle MAE ve MAPE değerlerindeki düşüş, modelin günlük tahmin başarısının belirgin şekilde arttığını göstermektedir. R² değerinin yaklaşık %90 seviyesine yükselmesi, modelin veri içerisindeki

örüntüleri çok daha başarılı şekilde öğrendiğini göstermektedir. Modelin genelleme performansını değerlendirmek amacıyla optimize edilmiş yapı daha önce görülmemiş test veri seti üzerinde de analiz edilmiştir. Başlangıç modeli ile optimize edilmiş test sonuçları karşılaştırıldığında önemli performans iyileşmeleri gözlemlenmiştir.

Bu sonuçlar hiperparametre optimizasyonunun model başarısı üzerinde önemli katkılar sağladığını göstermektedir. Özellikle MAE değerinde yaklaşık %53, MAPE değerinde yaklaşık %55 ve RMSE değerinde yaklaşık %41 iyileşme sağlanmıştır.

Ayrıca test sonuçlarının doğrulama sonuçlarına yakın seviyelerde gerçekleşmesi, modelin yalnızca eğitim verisini ezberlemediğini ve aşırı öğrenme (overfitting) probleminin sınırlı düzeyde kaldığını göstermektedir. Test veri setinde elde edilen $R^2 = 0.7872$ değeri, Brent petrol fiyat hareketlerinin yaklaşık %79'unun model tarafından açıklanabildiğini göstermektedir.

Genel olarak değerlendirildiğinde XGBoost modeli; Brent petrol fiyatlarının genel trendlerini başarılı şekilde öğrenebilmiş, volatilité ve jeopolitik risk değişkenlerinden anlamlı bilgi çıkarabilmiştir. Ancak ani piyasa şokları ve zaman bağımlılıklarının yoğun olduğu dönemlerde hata seviyelerinde artış gözlemlenmiştir. Bu nedenle bir sonraki aşamada zaman serilerindeki ardışık bağımlılıkları öğrenme kapasitesi daha yüksek olan LSTM modeli değerlendirilmiştir.



Şekil 5. XGBoost Gerçek vs. Tahmin Grafiği

Şekil 5 incelendiğinde XGBoost modelinin Brent petrol fiyatlarındaki genel eğilimi başarılı şekilde takip edebildiği görülmektedir. Model, özellikle orta ve uzun dönemli trend değişimlerini yakalayabilmiş ve gerçek fiyat hareketlerine benzer bir yapı oluşturmuştur. Ancak tahmin eğrisi incelendiğinde modelin gerçek seriye kıyasla daha yumuşak bir yapı sergilediği dikkat çekmektedir.

Özellikle ani yükseliş ve düşüşlerin yaşandığı bölgelerde modelin gerçek fiyat hareketlerini tam olarak takip edemediği ve tepe ile dip noktalarını bastırma eğilimi gösterdiği görülmektedir. Bu durum

XGBoost modelinin genel örüntüleri öğrenmede başarılı olmasına rağmen yüksek volatilité içeren kısa dönemli hareketleri modellemede sınırlı kalabildiğini göstermektedir.

Bununla birlikte tahmin eğrisi ile gerçek değerler arasındaki farkın genel olarak düşük seviyede kalması ve modelin $R^2=0.7872$ açıklayıcılık düzeyine ulaşması, Brent petrol fiyatlarındaki değişkenliğin önemli bir bölümünün başarıyla öğrenildiğini göstermektedir. Özellikle düşük MAPE (%2,89) değeri de modelin görelî hata açısından başarılı tahminler ürettiğini desteklemektedir.

LSTM Modeli

XGBoost modelinin ardından, zaman serilerindeki ardışık bağımlılıkları daha etkin şekilde öğrenebilmek amacıyla Long Short-Term Memory (LSTM) modeli geliştirilmiştir. LSTM, geleneksel yapay sinir ağlarından farklı olarak geçmiş zaman adımlarına ait bilgileri hafızasında tutabilen bir derin öğrenme mimarisidir. Finansal zaman serilerinde fiyat hareketleri yalnızca mevcut gün verilerinden değil, geçmiş dönem davranışlarından da etkilendiği için LSTM yapısının petrol fiyat tahmini açısından uygun bir yöntem olacağı değerlendirilmiştir.

LSTM modelinin oluşturulabilmesi için veri seti sequence (dizi) yapısına dönüştürülmüştür. Modelin geçmiş bilgileri öğrenebilmesi amacıyla pencere uzunluğu (WINDOW_SIZE) değeri 10 olarak belirlenmiştir. Böylece model her tahmin için geçmiş 10 zaman adımını kullanarak bir sonraki Brent petrol fiyatını tahmin edecek şekilde yapılandırılmıştır. Oluşturulan veri yapısı; Eğitim Veri Seti (1744, 10, 32), Doğrulama Veri Seti (366, 10, 32), ve Test Veri Seti (366, 10, 32) şeklindedir.

Burada ilk boyut örnek sayısını, ikinci boyut zaman penceresini, üçüncü boyut ise modele verilen özellik sayısını ifade etmektedir. Böylece veri yapısı klasik iki boyutlu makine öğrenmesi formatından çıkarılarak LSTM mimarisine uygun üç boyutlu forma dönüştürülmüştür.

İlk aşamada temel LSTM mimarisi oluşturulmuş ve model performansı değerlendirilmiştir. Kullanılan mimari iki LSTM katmanı ve tam bağılı (dense) katmanlardan oluşmaktadır. Model yapısı Tablo 10'da oluşturulmuştur.

Tablo 10 LSTM Modeli

Katman	Çıktı Boyutu	Parametre Sayısı	Açıklama
lstm_0	(None, 10, 64)	24.832	Zaman serisindeki geçmiş bilgileri öğrenen ilk LSTM katmanıdır. Veri içerisindeki kısa ve uzun dönemli bağımlılıkları yakalayarak sonraki katmanlara aktarır.
dropout_0	(None, 10, 64)	0	Aşırı öğrenmeyi (overfitting) azaltmak amacıyla eğitim sırasında bazı nöronları rastgele devre dışı bırakan katmandır.
lstm_1	(None, 32)	12.416	İlk LSTM katmanından gelen bilgileri işleyerek daha karmaşık zaman serisi örüntülerini öğrenen ikinci LSTM katmanıdır.
dropout_1	(None, 32)	0	İkinci LSTM katmanından sonra kullanılarak modelin genelleme yeteneğini artırmayı amaçlayan düzenleştirme katmanıdır.
dense_0	(None, 16)	528	LSTM katmanlarından elde edilen özellikleri birleştirerek nihai tahmin için daha anlamlı temsiller oluşturan tam bağlantılı katmandır.
dense_1	(None, 1)	17	Modelin son çıkış katmanı olup bir sonraki günün Brent petrol fiyat tahminini üretmektedir.


Toplam model parametre sayısı 37.793 olarak hesaplanmıştır.

Model eğitimi sırasında aşırı öğrenmeyi (overfitting) azaltmak amacıyla dropout katmanları kullanılmıştır. Ayrıca eğitim sürecinde erken durdurma (Early Stopping) mekanizması uygulanmıştır. Bu kapsamda doğrulama kaybı (validation loss) izlenmiş ve doğrulama kaybının 30 ardışık epok boyunca iyileşme göstermemesi durumunda eğitim süreci otomatik olarak sonlandırılmıştır. Model en fazla 200 epok boyunca eğitilecek şekilde yapılandırılmış olmakla birlikte, erken durdurma mekanizması sayesinde gereksiz eğitim süreçlerinin önüne geçilmiştir. Ayrıca “restore_best_weights=True” parametresi kullanılarak doğrulama veri setinde en düşük hata değerini sağlayan model ağırlıkları geri yüklenmiştir. Böylece modelin eğitim verisini ezberleme eğilimi azaltılmış ve genelleme performansının artırılması amaçlanmıştır.

İlk LSTM modeli test veri seti üzerinde değerlendirildiğinde aşağıdaki sonuçlar elde edilmiştir:

- RMSE = 5,37 dolar
- MAE = 4,25 dolar
- MAPE = %4,80
- $R^2 = 0.5086$

Elde edilen sonuçlar modelin petrol fiyat hareketlerini belirli ölçüde öğrenebildiğini göstermiştir. Ancak hata oranlarının beklenen seviyelerin üzerinde olduğu ve açıklayıcılık düzeyinin sınırlı kaldığı görülmüştür. Özellikle XGBoost modeli ile karşılaştırıldığında LSTM modelinin veri içerisindeki örüntüleri yeterli düzeyde öğrenemediği değerlendirilmiştir.



Şekil 6. LSTM Loss Grafiği

Şekil 6 incelendiğinde eğitim süreci boyunca training loss değerinin düzenli şekilde azaldığı ve modelin eğitim verisindeki örüntüleri başarılı biçimde öğrendiği görülmektedir. İlk epochlarda hızlı bir düşüş gerçekleşmiş, sonraki aşamalarda ise kayıp değeri daha kararlı bir yapıya yaklaşmıştır.

Buna karşılık validation loss değerinin sürekli azalmadığı ve dalgalı bir yapı sergilediği görülmektedir. Bunun temel nedeni petrol fiyatlarının yüksek volatiliteye sahip olması ve doğrulama veri setindeki örüntülerin eğitim verisinden farklı davranabilmesidir. Ayrıca training ve validation loss arasındaki fark, modelin belirli düzeyde overfitting eğilimi taşıdığını göstermektedir. Bu nedenle eğitim sürecinde Early Stopping kullanılarak aşırı öğrenme etkisi sınırlandırılmıştır.

Bu nedenle model üzerinde hiperparametre optimizasyon sürecine geçilmiştir. LSTM modellerinde katman boyutları, öğrenme oranı ve dropout değerleri performansı önemli ölçüde etkileyebildiğinden farklı mimari kombinasyonları test edilmiştir.

Gerçekleştirilen optimizasyon sürecinde aşağıdaki parametreler değerlendirilmiştir:

- LSTM katman boyutları
- Dropout oranları
- Dense katman boyutları
- Öğrenme oranı (learning rate)

Tablo 11 LSTM Hiperparametre Havuzu

units1 = 32	units2 = 16	droupout = 0.20	dense_units = 8	learning_rate = 0.001
units1 = 64	units2 = 32	droupout = 0.20	dense_units = 16	learning_rate = 0.001
units1 = 64	units2 = 32	droupout = 0.30	dense_units = 16	learning_rate = 0.0005
units1 = 128	units2 = 64	droupout = 0.30	dense_units = 32	learning_rate = 0.0005
units1 = 32	units2 = 16	droupout = 0.10	dense_units = 8	learning_rate = 0.0005

Tablo 11’de verilen hiperparametre değerleri ile toplam beş farklı model mimarisi test edilmiş ve sonuçlar doğrulama veri seti üzerinden karşılaştırılmıştır. En başarılı yapı;

units1 = 64, units2 = 32, dropout = 0.2, dense_units = 16 ve learning_rate = 0.001 değerleri ile elde edilmiştir.

Bu yapı doğrulama aşamasında:

- Validation Loss: 0.005154
- Validation MAE: 0.052102
- Eğitim süresi: 42 epoch sonuçlarını üretmiştir.

Dikkat çekici noktalardan biri, modelin 200 epoch olarak tanımlanmasına rağmen en iyi sonucun 42. epochta elde edilmesidir. Early Stopping mekanizması sayesinde modelin daha uzun süre eğitilmesi engellenmiş ve aşırı öğrenme riski azaltılmıştır.

Optimize edilen model test veri seti üzerinde tekrar değerlendirildiğinde aşağıdaki sonuçlar elde edilmiştir:


- RMSE = 4,29 dolar
- MAE = 3,40 dolar
- MAPE = %3,91
- $R^2 = 0.6868$

Tablo 1 LSTM Sonuçları

	LSTM	Optimize Edilmiş LSTM
RMSE	5.37 \$	4.29 \$
MAE	4.25 \$	3.40 \$
MAPE	%4,80	%3,90
R ²	0.5086	0.6868

Tablo 12’deki sonuçlar hiperparametre optimizasyonunun model başarısına doğrudan katkı sağladığını göstermektedir. Özellikle RMSE ve MAE değerlerinde önemli düşüşler meydana gelirken açıklayıcılık düzeyi yaklaşık %35 artış göstermiştir.

Genel olarak değerlendirildiğinde LSTM modeli zaman bağımlılıklarını öğrenme konusunda başarılı performans göstermiştir. Ancak XGBoost modeline kıyasla daha yüksek hata oranları üretmesi ve eğitim sürecinde daha fazla hesaplama maliyeti gerektirmesi nedeniyle tek başına yeterli görülmemiştir. Bu nedenle bir sonraki aşamada XGBoost ve LSTM modellerinin güçlü yönlerini birleştiren hibrit model yaklaşımına geçilmiştir.



Şekil 7 LSTM Gerçek vs. Tahmin Grafiği

Şekil 7 incelendiğinde LSTM modelinin Brent petrol fiyatlarındaki genel eğilimleri takip edebildiği görülmektedir. Model özellikle orta ve uzun dönemli trend değişimlerini öğrenebilmiş, gerçek fiyat serisi ile benzer yönlü hareketler sergilemiştir. Ancak tahmin eğrisinin gerçek seriye göre daha yumuşak ve gecikmeli bir yapı oluşturduğu dikkat çekmektedir.

Özellikle ani yükseliş ve düşüşlerin yaşandığı bölgelerde modelin tepe ve dip noktalarını tam olarak yakalayamadığı görülmektedir. Bu durum LSTM modelinin zaman serilerindeki genel bağımlılıkları öğrenebilmesine rağmen, petrol piyasalarındaki yüksek volatilité ve ani kırılmaları modellemede sınırlı kalabildiğini göstermektedir.

Bununla birlikte modelin genel eğilimi başarılı şekilde takip etmesi ve optimize edilmiş modelde $R^2=0.6868$ seviyesine ulaşması, LSTM yapısının zaman serilerindeki ardışık ilişkileri öğrenme açısından anlamlı katkı sağladığını göstermektedir.

Hibrit Model

XGBoost ve LSTM modellerinin ayrı ayrı değerlendirilmesinin ardından, her iki modelin güçlü yönlerini tek bir yapı altında birleştirebilmek amacıyla hibrit model yaklaşımı geliştirilmiştir. XGBoost modeli özellikler arası doğrusal olmayan ilişkileri öğrenmede güçlü performans sergilerken, LSTM modeli zaman serilerindeki ardışık bağımlılıkları ve geçmiş bilgi etkilerini öğrenebilmektedir. Bu nedenle iki modelin birlikte kullanılmasının daha güçlü bir tahmin performansı sağlayabileceği düşünülmüştür.

Hibrit model yapısında doğrudan ham veriler kullanılmamıştır. İlk aşamada XGBoost ve LSTM modellerinden elde edilen tahminler yeni bir veri seti oluşturmak amacıyla kullanılmıştır. Başka bir ifadeyle, iki modelin tahmin çıktıları bir üst modele giriş değişkeni olarak verilmiştir. Böylece meta-learning (stacking) tabanlı bir hibrit yapı oluşturulmuştur.

Bu kapsamda ilk olarak doğrulama veri seti üzerinde XGBoost ve LSTM tahminleri elde edilmiştir. Ancak LSTM modelinde pencereleme işlemi nedeniyle veri kaybı olduğundan tahmin serileri yeniden hizalanmıştır. Özellikle LSTM modelinin WINDOW_SIZE kadar gözlem kaybetmesi nedeniyle XGBoost tahminleri de aynı zaman yapısına uyarlanmıştır. Bu hizalama işlemi, iki modelin aynı gözlemler üzerinden öğrenmesini sağlamak amacıyla gerçekleştirilmiştir.

İlk hibrit modelde meta öğrenici olarak Ridge Regresyon yaklaşımı kullanılmıştır. Modelin öğrenme sonucunda elde edilen katsayılar aşağıdaki şekilde gerçekleşmiştir:

- XGBoost ağırlığı: 0.6623
- LSTM ağırlığı: 0.5224
- Sabit: -0.0776

Elde edilen katsayılar her iki modelin de hibrit yapı içerisinde anlamlı katkı sağladığını göstermektedir. Katsayıların birbirine yakın seviyelerde olması, modelin yalnızca tek bir yapıya bağımlı kalmadığını ve her iki algorithmadan bilgi üretebildiğini göstermektedir.

İlk hibrit model test sonuçları Tablo 13' de verilmiştir.

Tablo 2 Hibrit Model Sonuçları

RMSE	3.45 \$
MAE	2.79 \$
MAPE	%3.33
R ²	0.7969

Sonuçlar XGBoost ve LSTM modelleriyle karşılaştırıldığında hibrit yaklaşımın performans artışı sağladığı görülmüştür. Özellikle LSTM modeline kıyasla hata oranlarının düştüğü ve açıklayıcılık düzeyinin arttığı gözlemlenmiştir. Bununla birlikte meta model yapısının daha da iyileştirilmesi amacıyla hiperparametre optimizasyon sürecine geçilmiştir.

Bu aşamada meta öğrenici olarak farklı regresyon ve ensemble algoritmaları değerlendirilmiştir. Amaç, XGBoost ve LSTM çıktılarının hangi model yapısı altında daha başarılı bir şekilde birleştirilebileceğini belirlemektir. Bu kapsamda aşağıdaki modeller test edilmiştir:

- Linear Regression
- Ridge Regression
- Lasso Regression
- ElasticNet
- Random Forest Regressor
- XGBoost Regressor

Tablo 3 Hibrit Model Hiperparametre Sonuçları

Model	RMSE (\$)	MAE (\$)	MAPE (%)	R ²
Lasso_0.001	3.03	2.53	3.01	0.843
Linear_Regression	3.10	2.56	3.04	0.835
Ridge_0.001	3.10	2.56	3.04	0.835
Ridge_0.01	3.12	2.57	3.05	0.833
Ridge_0.1	3.24	2.64	3.15	0.820
ElasticNet_0.001	3.27	2.66	3.18	0.817
Ridge_5	3.41	2.82	3.38	0.801
ElasticNet_0.01	3.43	2.85	3.40	0.799
Ridge_1	3.45	2.79	3.34	0.796
XGBoost_Meta	3.46	2.40	2.73	0.795
Lasso_0.01	3.57	2.99	3.51	0.782
Ridge_10	3.80	3.13	3.70	0.753
RandomForest_Meta	4.35	2.95	3.35	0.677

Tablo 14'teki test sonuçları incelendiğinde en düşük hata değerlerinin Lasso ($\alpha=0.001$) modelinde elde edildiği görülmüştür.

İlk bakışta Lasso modeli en başarılı yapı olarak görünmektedir. Ancak model katsayıları incelendiğinde önemli bir durum tespit edilmiştir. Lasso yapısı L1 düzenleme özelliği nedeniyle bazı değişkenlerin ağırlıklarını sıfıra çekebilmektedir. Çalışmada gerçekleştirilen analiz sonucunda Lasso modelinin LSTM model ağırlığını sıfıra düşürdüğü görülmüştür. Bu durumda hibrit yapı fiilen yalnızca XGBoost modeline dayalı hale gelmiştir.

Bu durum hibrit model mantığı açısından uygun görülmemiştir. Çünkü çalışmanın amacı iki farklı modelin güçlü yönlerini birlikte kullanmak ve zaman bağımlılığı bilgisini de tahmin sürecine dahil etmektir. LSTM katkısının ortadan kalkması durumunda model gerçek anlamda hibrit özellik taşımamaktadır. Bu nedenle en iyi ikinci sonuçları veren lineer regresyon yapısı tercih edilmiştir.

Bu yapı için elde edilen katsayılar:

- XGBoost ağırlığı: 1.1243
- LSTM ağırlığı: 0.1402
- Sabit: -0.1320

Katkı oranları incelendiğinde:

- XGBoost katkısı: %88,91
- LSTM katkısı: %11,09 olarak hesaplanmıştır.

Sonuçlar hibrit model içerisinde XGBoost modelinin daha baskın rol üstlendiğini göstermektedir. Bununla birlikte LSTM modeli de tamamen dışlanmamış ve zamansal bağımlılık bilgisini hibrit yapıya taşımıştır. Böylece hem özellik tabanlı öğrenme hem de zaman bağımlılığı aynı yapı içerisinde kullanılabilmiştir.

Tablo 4 Optimize Edilmiş Hibrit Model Sonuçları


RMSE	3.10 \$
MAE	2.55 \$
MAPE	%3.04
R ²	0.8356

Tablo 15'te lineer regresyon kullanılarak optimize edilmiş hibrit model sonuçları verilmiştir. Genel olarak değerlendirildiğinde hibrit yaklaşım, tekil modellerin güçlü yönlerini bir araya getirerek daha yüksek açıklayıcılık ve daha düşük hata oranları üretmiştir. Özellikle Brent petrol fiyatlarının karmaşık ve yüksek volatil yapısı dikkate alındığında, çoklu model yaklaşımının daha güçlü sonuçlar sağlayabildiği görülmüştür.

Tablo 5 Modellerin Performans Metrikleri Karşılaştırılması

	XGBoost	LSTM	Hibrit
RMSE	3.72 \$	4.29 \$	3.10 \$
MAE	2.65 \$	3.40 \$	2.55 \$
MAPE	%2,90	%3,90	%3,04
R ²	0.7872	0.6868	0.8356

Tablo 16 genel olarak değerlendirildiğinde, hibrit model yaklaşımının tekil model yapılarına kıyasla daha dengeli ve güçlü sonuçlar ürettiği görülmektedir. XGBoost modeli fiyat hareketlerindeki genel örüntüleri başarılı şekilde yakalayarak güçlü performans sergilerken, LSTM modeli zaman serilerindeki ardışık ilişkileri öğrenebilmesine rağmen yüksek volatilité içeren hareketlerde daha sınırlı kalmıştır. İki modelin birlikte kullanıldığı hibrit yapı ise her iki yöntemin güçlü yönlerini bir araya getirerek daha kararlı tahminler üretmiştir. Bu durum, petrol gibi karmaşık ve doğrusal olmayan finansal zaman serilerinde hibrit modelleme yaklaşımının önemli avantajlar sağlayabileceğini göstermektedir.



Şekil 8. Hibrit Model Gerçek vs. Tahmin Grafiği

Şekil 8 incelendiğinde hibrit modelin Brent petrol fiyatlarındaki genel eğilimi oldukça başarılı şekilde takip ettiği görülmektedir. Tahmin eğrisi gerçek seri ile büyük ölçüde benzer hareketler sergilemekte ve özellikle orta–uzun dönemli trend değişimlerini başarılı biçimde yakalayabilmektedir. XGBoost ve LSTM modellerinin birlikte kullanılması sayesinde tahmin eğrisinin gerçek verilere daha yakın bir yapı oluşturduğu dikkat çekmektedir.

Bununla birlikte modelin ani yükseliş ve düşüşlerin yaşandığı bazı bölgelerde gerçek seriye göre daha yumuşak bir yapı sergilediği görülmektedir. Özellikle kısa dönemli sert kırılmalarda tepe ve dip

noktalarını tam olarak yakalayamadığı gözlemlense de genel eğilimleri başarılı şekilde takip edebilmiştir. Bu durum hibrit model yapısının petrol piyasalarındaki karmaşık örüntüleri öğrenme konusunda tekil modellere kıyasla daha güçlü performans sunduğunu desteklemektedir.

BÖLÜM 5. ANALİZ

5.1. Diebold-Mariano Testi

Bu çalışmada geliştirilen XGBoost, LSTM ve Hibrit modellerinin performansları RMSE, MAE, MAPE ve R^2 gibi performans metrikleri kullanılarak değerlendirilmiştir. Ancak bu metrikler modeller arasındaki performans farklarının büyüklüğünü göstermekle birlikte, söz konusu farkların istatistiksel olarak anlamlı olup olmadığını ortaya koymamaktadır. Başka bir ifadeyle, iki model arasında gözlenen performans farkı rastlantısal nedenlerden kaynaklanabileceği gibi, modellerden birinin gerçekten daha başarılı olmasından da kaynaklanabilmektedir. Bu nedenle çalışmada modeller arasındaki tahmin performansı farklılıklarının istatistiksel olarak değerlendirilmesi amacıyla Diebold–Mariano (DM) testi uygulanmıştır.

Diebold ve Mariano (1995) tarafından geliştirilen bu test, aynı veri seti üzerinde tahmin üreten iki modelin hata serilerini karşılaştırarak tahmin performanslarının eşit olup olmadığını incelemektedir. Testin temel mantığı, iki modele ait tahmin hataları arasındaki farkların analiz edilmesine dayanmaktadır. Eğer iki model benzer performans gösteriyorsa hata farklarının ortalamasının sıfıra yakın olması beklenmektedir. Buna karşılık hata farklarının sistematik şekilde sıfırdan uzaklaşması, modellerden birinin diğerine göre daha başarılı olduğunu göstermektedir.

Bu çalışmada DM testinin tercih edilmesinin temel nedeni, petrol fiyat tahmini gibi zaman serisi problemlerinde yaygın olarak kullanılan bir model karşılaştırma yöntemi olmasıdır. Çalışma kapsamında geliştirilen XGBoost, LSTM ve Hibrit modelleri aynı test veri seti üzerinde değerlendirilmiş ve böylece hata serilerinin doğrudan karşılaştırılması mümkün olmuştur. Özellikle hibrit model yaklaşımının sağladığı performans artışının istatistiksel olarak anlamlı olup olmadığının belirlenmesi açısından DM testi çalışmanın amacıyla doğrudan örtüşmektedir.

Diebold–Mariano testinde öncelikle iki modelin tahmin hataları arasındaki fark serisi hesaplanmaktadır. Hata farkı serisi Denklem 9'daki gibi tanımlanmaktadır:

$$d_t = L(e_{1,t}) - L(e_{2,t}) \quad (9)$$

Burada;

- d_t : İki model arasındaki hata farkını,
- $L(.)$: Kayıp fonksiyonunu,
- $e_{1,t}$: Birinci modelin tahmin hatasını,
- $e_{2,t}$: İkinci modelin tahmin hatasını ifade etmektedir.

Bu çalışmada kayıp fonksiyonu olarak karesel hata yaklaşımı kullanılmıştır. Test kapsamında kurulan hipotezler Denklem 10'da verilmiştir:

$$H_0: E(d_t) = 0$$

$$H_1: E(d_t) \neq 0 \quad (10)$$

Sıfır hipotezi (H_0), karşılaştırılan iki modelin tahmin performanslarının eşit olduğunu ve hata farklarının ortalamasının sıfır olduğunu ifade etmektedir. Alternatif hipotez (H_1) ise modeller arasında istatistiksel olarak anlamlı bir performans farkı bulunduğunu göstermektedir.

DM test istatistiği Denklem 11 yardımıyla hesaplanmaktadır:

$$DM = \frac{\bar{d}}{\sqrt{\frac{\text{Var}(d)}{T}}} \quad (11)$$

Burada;

- $\bar{d}$: Hata farkları serisinin ortalamasını,
- $\text{Var}(d)$: Hata farklarının varyansını,
- T : Gözlem sayısını ifade etmektedir.

Test sonucunda elde edilen p-değeri 0.05 anlamlılık seviyesinden küçük ise sıfır hipotezi reddedilmekte ve modeller arasındaki performans farkının istatistiksel olarak anlamlı olduğu kabul edilmektedir. Buna karşılık p-değerinin 0.05'ten büyük olması durumunda modeller arasındaki farkın istatistiksel olarak anlamlı olmadığı sonucuna ulaşılmaktadır.

Bu çalışmada Diebold–Mariano testi; Hibrit–XGBoost, Hibrit–LSTM ve XGBoost–LSTM model çiftleri için uygulanmıştır. Böylece performans metrikleriyle elde edilen sonuçların istatistiksel açıdan doğrulanması ve modeller arasındaki göreceli başarı düzeylerinin daha kapsamlı biçimde değerlendirilmesi amaçlanmıştır. Özellikle hibrit model yaklaşımının sağladığı performans iyileşmesinin anlamlı olup olmadığının belirlenmesi, çalışmanın temel araştırma sorularından birini oluşturmaktadır.

Tablo 17 Diebold-Mariano Testi Sonuçları

Model	DM Test İstatistiği	P Değeri
Hibrit – XGBoost	-0.8423	0.4002
Hibrit – LSTM	-6.8546	0.0
XGBoost – LSTM	-10.2219	0.0

Tablo 17’de verilen Diebold–Mariano test sonuçları incelendiğinde, hibrit model ile XGBoost modeli arasında istatistiksel olarak anlamlı bir performans farkı bulunmadığı görülmektedir ($p=0.4002>0.05$). Her ne kadar performans metrikleri hibrit modelin daha düşük hata değerlerine sahip olduğunu

gösterse de elde edilen farkın istatistiksel açıdan anlamlı olmadığı belirlenmiştir. Bu durum, hibrit modelin sağladığı performans iyileşmesinin sınırlı düzeyde kaldığını ve XGBoost modelinin de benzer tahmin başarısı sergilediğini göstermektedir.

Buna karşılık hibrit model ile LSTM modeli arasındaki karşılaştırmada p-değerinin 0.05'ten küçük olduğu görülmektedir. Elde edilen negatif DM değeri, hibrit modelin LSTM modeline kıyasla daha düşük tahmin hatalarına sahip olduğunu göstermektedir. Benzer şekilde XGBoost ve LSTM modelleri arasındaki karşılaştırmada da istatistiksel olarak anlamlı bir fark tespit edilmiş ve XGBoost modelinin LSTM modeline göre daha başarılı sonuçlar ürettiği belirlenmiştir.

Genel olarak Diebold–Mariano testi sonuçları, çalışmada geliştirilen hibrit model ile XGBoost modelinin benzer performans seviyelerinde bulunduğunu, buna karşın her iki modelin de LSTM modeline göre istatistiksel olarak anlamlı düzeyde daha başarılı tahminler ürettiğini ortaya koymaktadır. Bu sonuçlar, Brent petrol fiyat tahmininde ağaç tabanlı öğrenme yöntemlerinin ve hibrit modelleme yaklaşımlarının zaman serisi tabanlı derin öğrenme modeline kıyasla daha etkili sonuçlar verebildiğini göstermektedir.

5.2. SHAP Analizi

Makine öğrenmesi modelleri yüksek tahmin performansı sağlayabilmelerine rağmen, çoğu zaman karar mekanizmalarının yorumlanması zor olan "kara kutu" (black-box) yapılar olarak değerlendirilmektedir. Özellikle XGBoost gibi karmaşık ağaç tabanlı modellerde bir tahmin sonucunun hangi değişkenlerden ne ölçüde etkilendiğini doğrudan gözlemlemek mümkün değildir. Bu durum, modelin güvenilirliğinin değerlendirilmesini ve elde edilen sonuçların yorumlanmasını zorlaştırabilmektedir.

Bu çalışmada model tahminlerinin yorumlanabilmesi amacıyla SHAP (SHapley Additive Explanations) yöntemi kullanılmıştır. SHAP yöntemi, oyun teorisinde yer alan Shapley değerleri yaklaşımına dayanmaktadır. Temel amaç, model tarafından üretilen her tahmin sonucunu oluşturan değişkenlerin katkılarını adil bir şekilde dağıtmak ve her değişkenin tahmin üzerindeki etkisini sayısal olarak ortaya koymaktır.

SHAP yöntemi her bir değişkenin model çıktısına yaptığı marjinal katkıyı hesaplamaktadır. Bu sayede yalnızca değişkenlerin önem sıralaması elde edilmemekte, aynı zamanda ilgili değişkenin tahmini hangi yönde etkilediği de analiz edilebilmektedir. Pozitif SHAP değerleri değişkenin tahmin sonucunu artırıcı yönde etkilediğini, negatif SHAP değerleri ise tahmin sonucunu azaltıcı yönde etkilediğini göstermektedir.

Bu çalışmada SHAP analizinin tercih edilmesinin temel nedeni, Brent petrol fiyatlarının tahmininde kullanılan OVX ve GPR değişkenlerinin model üzerindeki etkilerinin nicel olarak ölçülmek

istenmesidir. Performans metrikleri modellerin ne kadar başarılı olduğunu göstermesine rağmen, tahmin başarısının hangi değişkenlerden kaynaklandığını açıklayamamaktadır. SHAP analizi sayesinde geçmiş Brent petrol fiyatları, volatilité göstergeleri ve jeopolitik risk değişkenlerinin model karar mekanizmasına yaptıkları katkılar ayrı ayrı incelenebilmiştir.


SHAP yönteminin temel varsayımı, model çıktısının her bir değişkenin katkılarının toplamı şeklinde ifade edilebilmesidir. Bu yaklaşım sayesinde model tahmini Denklem 12'deki gibidir:

$$f(x) = \phi_0 + \sum_{i=1}^n \phi_i \quad (12)$$

Burada;

- $f(x)$: Model tarafından üretilen tahmin sonucunu,
- ϕ_0 : Modelin temel (beklenen) tahmin değerini,
- ϕ_i : i'nci değişkenin tahmine yaptığı katkıyı ifade etmektedir.

Bu çalışmada SHAP analizi XGBoost modeli üzerinde uygulanmış ve değişkenlerin petrol fiyat tahminine katkıları hem küresel (global) hem de yerel (local) düzeyde incelenmiştir. Böylece yalnızca model performansı değil, modelin karar mekanizması da açıklanabilir hale getirilmiştir.



Şekil 9 SHAP Özet Grafiği


Şekil 9’da XGBoost modeli için elde edilen SHAP özet grafiği gösterilmektedir. Bu grafik değişkenlerin model tahminleri üzerindeki göreceli önemlerini, katkı büyüklüklerini ve model karar mekanizmasındaki rollerini ortaya koymaktadır.

Sonuçlar incelendiğinde, model tahminlerinde en yüksek katkının Price_clean değişkeninden geldiği görülmektedir. Bu değişkeni sırasıyla Price_Lag1, Price_EMA5, Price_Lag2 ve Price_EMA20 değişkenleri takip etmektedir. Bu bulgu, Brent petrol fiyatının güncel ve geçmiş değerleri ile hareketli ortalamalarının gelecek fiyat tahminlerinde temel belirleyici olduğunu göstermektedir. Dolayısıyla modelin karar mekanizması büyük ölçüde petrol fiyat serisinin kendi zamansal bağımlılık yapısına dayanmaktadır.

Volatilite göstergelerini temsil eden OVX_EMA5, OVX_final ve OVX_EMA20 değişkenlerinin de modele katkı sağladığı görülmektedir. Bu değişkenlerin etkisi fiyat tabanlı değişkenlere kıyasla daha düşük seviyede olsa da piyasa oynaklığını temsil eden OVX bilgisinin tahmin sürecine ek açıklayıcı bilgi sunduğu anlaşılmaktadır. Özellikle OVX_EMA5 değişkeninin öne çıkması, kısa dönemli volatilité eğiliminin model tarafından daha anlamlı bulunduğunu göstermektedir.

Buna karşılık GPR_THREAT_Lag4, OVX_Lag2 ve GPR_THREAT_Lag3 değişkenlerinin SHAP değerlerinin sıfıra oldukça yakın olduğu görülmektedir. Bu durum, söz konusu değişkenlerin mevcut model yapısı içerisinde tahmin sonucuna anlamlı bir marjinal katkı sağlamadığını göstermektedir. Özellikle GPR Threat değişkenlerine ait gecikmeli değerlerin düşük önem seviyesinde kalması, jeopolitik tehdit bilgisinin model içerisinde yer alan diğer fiyat ve volatilité değişkenleri tarafından dolaylı olarak temsil ediliyor olabileceğine işaret etmektedir. Benzer şekilde OVX_Lag2 değişkeninin düşük katkı sağlaması, volatilité bilgisinin model tarafından daha güncel göstergeler olan OVX_final ve OVX_EMA5 üzerinden daha etkin şekilde öğrenildiğini göstermektedir.

Bu sonuç, ilgili değişkenlerin ekonomik olarak tamamen önemsiz olduğu anlamına gelmemektedir. SHAP analizi yalnızca bu değişkenlerin mevcut model, veri seti ve diğer özellikler birlikte değerlendirildiğinde tahmin sonucuna sınırlı ek katkı sağladığını göstermektedir. Genel olarak değerlendirildiğinde, model tahminlerinin büyük ölçüde Brent petrol fiyatının geçmiş hareketleri tarafından şekillendirildiği, buna karşın volatilité ve jeopolitik risk göstergelerinin de destekleyici bilgi sağladığı anlaşılmaktadır. Bu bulgu, çalışmada kullanılan çok kaynaklı veri yapısının petrol fiyat tahmininde ek açıklayıcı değer sunduğunu ortaya koymaktadır.



Şekil 10 SHAP Katkı Oranları Grafiği

Şekil 10’da SHAP analizi sonucunda elde edilen değişken gruplarının toplam katkı oranları gösterilmektedir. Sonuçlar incelendiğinde, model tahminlerinin büyük ölçüde Brent petrol fiyatına ait değişkenlerden beslendiği görülmektedir. Fiyat tabanlı değişkenlerin toplam katkı oranı %93,19 olarak hesaplanırken, OVX ve GPR değişkenlerinden oluşan dışsal değişken grubunun toplam katkı oranı %6,81 olarak bulunmuştur.

Elde edilen sonuçlar, Brent petrol fiyatının geçmiş değerleri ve bu değerlerden türetilen gecikmeli değişkenler ile hareketli ortalamaların model karar mekanizmasında baskın rol oynadığını göstermektedir. Bu durum, petrol fiyatlarının güçlü bir zamansal bağımlılık yapısına sahip olduğunu ve geçmiş fiyat hareketlerinin gelecek dönem fiyatlarının tahmininde temel bilgi kaynağı olarak kullanıldığını ortaya koymaktadır.

Bununla birlikte OVX ve GPR değişkenlerinin katkı oranı görece düşük olsa da tamamen ihmal edilebilir seviyede değildir. Özellikle piyasa volatilitesi ve jeopolitik riskleri temsil eden bu değişkenler, modele ek açıklayıcı bilgi sağlayarak tahmin performansını desteklemektedir. Nitekim SHAP analizinde volatilité göstergelerini temsil eden OVX değişkenlerinin, jeopolitik risk değişkenlerine kıyasla daha yüksek katkı sağladığı görülmüştür.

Genel olarak değerlendirildiğinde, model tahminlerinin temel belirleyicisinin geçmiş Brent petrol fiyatları olduğu, ancak volatilité ve jeopolitik risk göstergelerinin de tahmin sürecine ilave bilgi kazandırdığı sonucuna ulaşılmıştır. Bu bulgu, çalışmada kullanılan çok kaynaklı veri yaklaşımının petrol fiyat tahmininde katkı sağlayabildiğini ve yalnızca fiyat verilerine dayalı modellerin ötesinde ek açıklayıcı değişkenlerin kullanılmasının faydalı olabileceğini göstermektedir.

BÖLÜM 6. GERÇEKÇİ KISITLAR VE KOŞULLAR ALTINDA DEĞERLENDİRME

Ekonomik Açıdan Değerlendirme

Bu çalışmada geliştirilen Brent petrol fiyat tahmin modeli, işletmelerin maliyet planlaması ve stratejik karar alma süreçlerine katkı sağlayabilecek veri odaklı bir karar destek sistemi niteliği taşımaktadır. Özellikle enerji yoğun sektörlerde faaliyet gösteren üretim işletmeleri, lojistik şirketleri ve petrokimya temelli tedarik zincirlerinde petrol fiyatlarındaki ani değişimler doğrudan maliyet yapısını etkileyebilmektedir. Bu nedenle petrol fiyatlarının önceden tahmin edilebilmesi; satın alma zamanlaması, stok yönetimi, yakıt maliyet planlaması ve finansal riskten korunma stratejileri açısından ekonomik avantaj sağlayabilmektedir.

Çalışmada geliştirilen hibrit modelin yaklaşık %83–93 açıklayıcılık düzeyine ulaşması ve düşük hata oranları üretmesi, modelin karar destek mekanizmalarında kullanılabilirliğini göstermektedir. Bu tür veri odaklı tahminleme sistemleri, işletmelerin belirsizlik ortamında daha doğru bütçe planlamaları yapmasına yardımcı olabilir. Ayrıca sistemin yalnızca açık kaynaklı veri setleri ve yazılım araçları kullanılarak geliştirilmiş olması, ek yatırım maliyetlerini azaltmakta ve uygulanabilirliği artırmaktadır.

Sosyal ve Politik Açıdan Değerlendirme

Petrol fiyatları yalnızca ekonomik değişkenlerden etkilenmemekte; savaşlar, uluslararası krizler, diplomatik gerilimler ve küresel politik gelişmelerden de doğrudan etkilenmektedir. Bu nedenle çalışmada Jeopolitik Risk Endeksi (GPR) gibi değişkenlerin modele dahil edilmesi, petrol piyasalarının sosyal ve politik boyutlarının da değerlendirilmesini sağlamıştır.

Özellikle Rusya–Ukrayna savaşı, COVID-19 süreci ve Orta Doğu merkezli jeopolitik gerilimler gibi olaylar, enerji piyasalarında ciddi fiyat dalgalanmalarına neden olmuştur. Bu tür gelişmeler yalnızca finansal piyasaları değil; toplumların yaşam maliyetlerini, enerjiye erişimini ve üretim süreçlerini de etkileyebilmektedir. Dolayısıyla geliştirilen tahmin sistemi yalnızca finansal öngörü amacı taşımamakta, aynı zamanda küresel risklerin ekonomik etkilerini önceden analiz etmeye yönelik bir araç niteliği de taşımaktadır.

Toplumsal açıdan değerlendirildiğinde, petrol fiyatlarındaki değişimlerin ulaşım maliyetleri, enerji giderleri ve tüketici fiyatları üzerinde dolaylı etkiler oluşturduğu bilinmektedir. Bu nedenle daha doğru tahminleme sistemlerinin geliştirilmesi, işletmelerin yanı sıra politika yapıcılar ve karar vericiler açısından da önem taşımaktadır.

BÖLÜM 7. SONUÇ

Bu çalışmada, Brent ham petrol fiyatlarının tahmin edilmesinde geleneksel fiyat temelli yaklaşımların ötesine geçilerek; piyasa volatilitesi ve jeopolitik risk göstergelerini birlikte değerlendiren veri odaklı bir tahminleme sistemi geliştirilmiştir. Petrol piyasalarının yapısı incelendiğinde fiyat hareketlerinin yalnızca arz-talep dengesiyle açıklanamadığı; küresel krizler, savaşlar, finansal belirsizlikler ve yatırımcı davranışlarının da fiyat dinamikleri üzerinde etkili olduğu görülmektedir. Bu durum, petrol fiyat tahminleme problemini doğrusal olmayan, yüksek oynaklığa sahip ve çok değişkenli bir zaman serisi problemi haline getirmektedir.

Bu problemin çözümüne yönelik olarak çalışma kapsamında Brent petrol fiyatları ile birlikte Petrol, OVX, GPR ve GPR Threat değişkenleri kullanılmıştır. Veri seti 2014–2024 dönemini kapsayacak şekilde oluşturulmuş ve farklı kaynaklardan elde edilen veriler tarih bazında eşleştirilerek bütünleşik veri yapısı oluşturulmuştur. Ham veriler üzerinde gerçekleştirilen incelemelerde finansal serilerde yüksek oynaklık, aykırı değerler ve gürültü içeren yapıların bulunduğu görülmüştür. Bu nedenle modelleme öncesinde dalgacık dönüşümü ile gürültü azaltma işlemleri uygulanmış; logaritmik dönüşüm, winsorizasyon ve Min-Maks normalizasyon yöntemleri kullanılarak veri seti modellemeye uygun hale getirilmiştir.

Veri hazırlama sürecinden sonra özellik mühendisliği çalışmaları gerçekleştirilmiştir. Modelin zaman serilerindeki örüntüleri daha iyi öğrenebilmesi amacıyla gecikmeli değişkenler, hareketli ortalamalar ve EMA tabanlı özellikler oluşturulmuştur. Böylece yalnızca mevcut veri noktalarının değil, geçmiş davranışların da modele aktarılması sağlanmıştır. Özellikle petrol piyasalarında görülen ani sıçramalar ve gecikmeli etkiler düşünüldüğünde bu yaklaşımın tahmin performansı açısından önemli katkılar sağladığı görülmüştür.

Modelleme aşamasında üç farklı yapı geliştirilmiştir: XGBoost, LSTM ve Hibrit model. İlk aşamada XGBoost modeli oluşturulmuş ve temel model sonuçlarında $R^2=0.3823$ seviyesinde açıklayıcılık elde edilmiştir. Daha sonra gerçekleştirilen hiperparametre optimizasyonları sonucunda model performansı önemli ölçüde iyileşmiş ve test verileri üzerinde $R^2=0.7872$ sonuçlarına ulaşılmıştır. Bu durum hiperparametre optimizasyonunun model başarısı üzerindeki etkisini açık şekilde göstermiştir.

LSTM modeli tarafında zaman serilerinin ardışık yapısını öğrenebilmek amacıyla sekans tabanlı bir yapı kurulmuştur. İki katmanlı LSTM mimarisi, Dropout katmanları ve yoğun bağlantılı katmanlar kullanılarak oluşturulan modelde hiperparametre optimizasyonu uygulanmıştır. İlk model sonuçlarında

$R^2=0.5086$ seviyesinde açıklayıcılık elde edilirken optimizasyon sonrasında model performansı $R^2=0.6868$ seviyesine yükselmiştir. Ancak sonuçlar, LSTM modelinin Brent petrol fiyatlarındaki yüksek oynaklık ve ani kırılmaları modelleme konusunda belirli sınırlılıklar taşıdığını göstermiştir.

Çalışmanın son aşamasında XGBoost ve LSTM modellerinin güçlü yönlerini birleştirmek amacıyla hibrit model yaklaşımı geliştirilmiştir. İlk hibrit modelde Ridge tabanlı bir meta öğrenici kullanılmış ve $R^2=0.7969$ değeri elde edilmiştir. Daha sonra gerçekleştirilen meta model optimizasyon sürecinde farklı yöntemler değerlendirilmiştir. En yüksek performans Lasso modeli ile elde edilmiş olmasına rağmen, model LSTM katsayısını sıfıra indirerek yalnızca XGBoost çıktısını kullanmıştır. Bu nedenle hibrit model mantığını korumak amacıyla ikinci en iyi performansa sahip Linear Regression meta modeli tercih edilmiştir.

Final hibrit model sonuçları incelendiğinde $R^2=0.8356$ seviyesine ulaşıldığı görülmüştür. Model ağırlıkları analiz edildiğinde XGBoost katkısının %88.91, LSTM katkısının ise %11.09 olduğu hesaplanmıştır. Bu durum tahmin performansının temel taşıyıcısının XGBoost olduğunu ancak LSTM modelinin de ek bilgi sağlayarak modele katkı sunduğunu göstermektedir.

Model daha sonra 2024–2026 dönemini kapsayan yeni test veri seti üzerinde değerlendirilmiştir. Bu aşamada hibrit model $R^2=0.9340$ değerlerine ulaşmıştır. Önceki test sonuçlarına göre daha yüksek başarı elde edilmesinin, ilgili dönemdeki veri yapısının eğitim dönemine daha yakın örüntüler göstermesiyle ilişkili olduğu düşünülmektedir. Özellikle volatilité yapılarının benzerlik göstermesi modelin genelleme kabiliyetini olumlu etkilemiş görünmektedir.

İşletmeler açısından değerlendirildiğinde geliştirilen sistem önemli uygulama potansiyeline sahiptir. Üretim işletmeleri, lojistik firmaları ve enerji yoğun sektörlerde faaliyet gösteren kuruluşlar için petrol fiyatlarının önceden tahmin edilebilmesi; yakıt maliyet planlaması, satın alma süreçleri, bütçe yönetimi ve finansal risk stratejileri açısından önemli avantajlar sağlayabilir. Örneğin lojistik sektöründe yakıt maliyetlerinin önceden öngörülebilmesi rota planlama ve sözleşme süreçlerine katkı sağlayabilirken, üretim tesislerinde enerji maliyetlerinin tahmini bütçe sapmalarını azaltabilir.

Sonuç olarak bu çalışma yalnızca bir fiyat tahmin modeli geliştirmeyi değil; jeopolitik riskler ve piyasa belirsizliklerini dikkate alan veri temelli bir karar destek sistemi ortaya koymayı amaçlamıştır. Elde edilen bulgular, hibrit makine öğrenmesi modellerinin petrol fiyat tahmininde güçlü sonuçlar üretebildiğini ve çok kaynaklı veri kullanımının finansal zaman serilerinde önemli katkılar sağlayabildiğini göstermektedir.

Tablo 18 Model Sonuçları

Model	RMSE (\$)	MAE (\$)	NRMSE (%)	NMAE (%)	MAPE (%)	R ²	Açıklama
İlk XGBoost	6.35	5.67	7.40	6.61	6.50	0.382	Başlangıç modeli, optimize edilmemiş
Optimize XGBoost	3.72	2.65	4.34	3.08	2.90	0.787	Hiperparametre optimizasyonu sonrası önemli iyileşme
İlk LSTM	5.37	4.25	6.30	4.99	4.80	0.509	Temel sekans modeli
Optimize LSTM	4.29	3.40	5.03	3.99	3.91	0.687	Hiperparametre optimizasyonu sonrası iyileşme
İlk Hibrit (Ridge)	3.45	2.79	4.05	3.27	3.34	0.797	XGBoost + LSTM başlangıç hibrit yapı
Final Hibrit (Lineer)	3.11	2.56	3.64	3.00	3.04	0.836	Nihai seçilen model
2024–2026 Hibrit Test	2.78	2.08	3.69	2.76	2.67	0.934	Yeni dönem verilerindeki en başarılı sonuç

Tablo 18 incelendiğinde hiperparametre optimizasyonu ve hibrit modelleme yaklaşımının model performansı üzerinde önemli etkiler oluşturduğu görülmektedir. Özellikle nihai hibrit model hem hata metrikleri hem de açıklayıcılık düzeyi açısından diğer modellere göre daha başarılı sonuçlar üretmiştir. 2024–2026 veri seti üzerinde elde edilen %93,4 açıklayıcılık oranı, geliştirilen modelin farklı dönemlerde de güçlü tahmin performansı sergileyebildiğini göstermektedir.

KAYNAKLAR

- Alqahtani, A., Bouri, E., & Vo, X. V. (2020). Predictability of GCC stock returns: The role of geopolitical risk and crude oil returns. *Economic Analysis and Policy*, 68, 239-249.
- Antonakakis, N., Gupta, R., Kollias, C., & Papadamou, S. (2017). Geopolitical risks and the oil-stock nexus over 1899–2016. *Finance Research Letters*, 23, 165-173.
- Caldara, D., & Iacoviello, M. (n.d.). *Geopolitical Risk Index*. Retrieved June 3, 2026, from <https://www.matteoiacoviello.com/gpr.htm>
- Choudhary, J., Sharma, H. K., Malik, P., & Majumder, S. (2025). Price forecasting of crude oil using hybrid machine learning models. *Journal of Risk and Financial Management*, 18(7), 346.
- Dutta, A. (2017). Oil price uncertainty and clean energy stock returns: New evidence from crude oil volatility index. *Journal of Cleaner Production*, 164, 1157-1166.
- Iftikhar, H., Qureshi, M., Rodrigues, P. C., Iftikhar, M. U., & López-Gonzales, J. L. (2025). Daily crude oil prices forecasting using a novel hybrid time series technique. *IEEE Access*.
- Kaymak, Ö. Ö., & Kaymak, Y. (2022). Prediction of crude oil prices in COVID-19 outbreak using real data. *Chaos, Solitons & Fractals*, 158, 111990.
- Lin, Y., Chen, K., Zhang, X., Tan, B., & Lu, Q. (2022). Forecasting crude oil futures prices using BiLSTM-Attention-CNN model with Wavelet transform. *Applied Soft Computing*, 130, 109723.
- Liu, J., Ma, F., Tang, Y., & Zhang, Y. (2019). Geopolitical risk and oil volatility: A new insight. *Energy Economics*, 84, 104548.
- Mazzeu, J. H. G., Veiga, H., & Mariti, M. B. (2019). Modeling and forecasting the oil volatility index. *Journal of Forecasting*, 38(8), 773-787.
- Shaikh, I. (2019). The relation between implied volatility index and crude oil prices. *Engineering Economics*, 30(5), 556-566.
- Sharif, A., Aloui, C., & Yarovaya, L. (2020). COVID-19 pandemic, oil prices, stock market, geopolitical risk and policy uncertainty nexus in the US economy: Fresh evidence from the wavelet-based approach. *International review of financial analysis*, 70, 101496.
- Shen, L., Bao, Y., Hasan, N., Huang, Y., Zhou, X., & Deng, C. (2024). Intelligent crude oil price probability forecasting: Deep learning models and industry applications. *Computers in Industry*, 163, 104150.
- Tian, G., Peng, Y., & Meng, Y. (2023). Forecasting crude oil prices in the COVID-19 era: Can machine learn better?. *Energy Economics*, 125, 106788.
- Wei, X. (2026). Forecasting crude oil futures price with energy uncertainty: Evidence from machine learning methods. *PloS one*, 21(2), e0341496.

Xu, Z., Mohsin, M., Ullah, K., & Ma, X. (2023). Using econometric and machine learning models to forecast crude oil prices: Insights from economic history. *Resources Policy*, 83, 103614.

Yahoo Finance. (n.d.). *Brent crude oil futures historical data*. Retrieved June 3, 2026, from <https://finance.yahoo.com/quote/BZ=F/history>

Yahoo Finance. (n.d.). *CBOE Crude Oil Volatility Index historical data*. Retrieved June 3, 2026, from <https://finance.yahoo.com/quote/%5EOVX/history>

Yiğit, T., Aksoy, B., Ersoy, M., Şenol, R., & Salman, O. K. M. (2021). Petrol fiyatlarının zaman serileri ve LSTM modeli kullanılarak tahminlenmesi. *Uluslararası Teknolojik Bilimler Dergisi*, 13(1), 34-38.